



TRƯỜNG ĐẠI HỌC NGOẠI NGỮ - TIN HỌC THÀNH PHỐ HỒ CHÍ MINH
KHOA CÔNG NGHỆ THÔNG TIN



BÁO CÁO KẾT THÚC HỌC PHẦN
MÁY HỌC

PHÂN CỤM KHÁCH HÀNG BẰNG KMEANS

Giảng viên hướng dẫn: **ThS. Huỳnh Thành Lộc**

Sinh viên thực hiện:

- | | |
|-----------------------|------------|
| 1. Trương Gia Nghi | 23DH114778 |
| 2. Đoàn Thanh Sang | 23DH113038 |
| 3. Trần Lâm Hồng Liên | 23DH111855 |

Thành phố Hồ Chí Minh, 26 tháng 11 năm 2025



TRƯỜNG ĐẠI HỌC NGOẠI NGỮ - TIN HỌC THÀNH PHỐ HỒ CHÍ MINH
KHOA CÔNG NGHỆ THÔNG TIN



**BÁO CÁO KẾT THÚC HỌC PHẦN
MÁY HỌC**

PHÂN CỤM KHÁCH HÀNG BẰNG KMEANS

Mã lớp học phần: **251123018401**

Năm học: **2025 – 2026**

Học kỳ: **1**

Sinh viên thực hiện:

- | | |
|-----------------------|------------|
| 1. Trương Gia Nghi | 23DH114778 |
| 2. Đoàn Thanh Sang | 23DH113038 |
| 3. Trần Lâm Hồng Liên | 23DH111855 |

Thành phố Hồ Chí Minh, 26 tháng 11 năm 2025

MỤC LỤC

DANH MỤC HÌNH	i
DANH MỤC BẢNG	iii
CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI.....	1
1.1. Giới thiệu bài toán	1
1.2. Các công trình liên quan.....	2
CHƯƠNG 2. CHUẨN BỊ DỮ LIỆU	3
2.1. Giới thiệu tập dữ liệu	3
2.2. Tiền xử lý dữ liệu	9
2.2.1. Giá trị thiếu.....	9
2.2.2. Giá trị trùng lặp	11
2.2.3. Giá trị ngoại lai.....	14
2.2.4. Chuẩn hóa dữ liệu phân loại	18
2.2.5. Chuyển đổi kiểu dữ liệu và mã hóa	21
2.2.6. Tổng kết.....	22
2.3. Xây dựng đặc trưng.....	25
2.3.1. Feature Engineering.....	26
2.3.2. Feature Scaling	43
CHƯƠNG 3. XÂY DỰNG MÔ HÌNH	61
3.1. Giới thiệu mô hình.....	61
3.1.1. Khái niệm	61
3.1.2. Nguyên lý hoạt động	61
3.1.3. Ưu điểm	61
3.1.4. Hạn chế	61
3.2. Ví dụ minh họa.....	62
3.2.1. Ý tưởng triển khai.....	62
3.2.2. Công thức cốt lõi	62
3.2.3. Quy trình xây dựng mô hình	63
3.3. Cài đặt thuật toán.....	66
3.3.1. Khởi tạo tâm cụm	66
3.3.2. Gán cụm.....	67
3.3.3. Cập nhật tâm cụm	67
3.3.4. Lặp lại	68
3.4. Thước đo đánh giá mô hình.....	70
3.4.1. Tiêu chí đánh giá nội	70
CHƯƠNG 4. KẾT QUẢ THỰC NGHIỆM	71

4.1.	Mô hình tự cài đặt	71
4.1.1.	Demographic	71
4.1.2.	Product Channel	78
4.1.3.	RFM.....	83
4.2.	Sử dụng thư viện.....	91
4.2.1.	Demographic	91
4.2.2.	Product Channel	93
4.2.3.	RFM.....	95
CHƯƠNG 5. KẾT LUẬN		98
5.1.	Kết quả đạt được	98
5.2.	Những khó khăn, hạn chế.....	98
TÀI LIỆU THAM KHẢO		99
PHỤ LỤC		100

DANH MỤC HÌNH

Hình 2.1 Phân phối Age.....	26
Hình 2.2 Phân phối Income	27
Hình 2.3 Phân phối của Dependency_Ratio	28
Hình 2.4 Phân phối của Dependency_Ratio trước và sau transform.....	29
Hình 2.5 Tương quan giữa các đặc trưng Demographic	30
Hình 2.6 Product_HHI	31
Hình 2.7 Store_Preference	32
Hình 2.8 Web_Engagement	33
Hình 2.9 PC1_TotalPurchases	34
Hình 2.10 Các đặc trưng tham chiếu	35
Hình 2.11 Tương quan giữa các đặc trưng Product Channel	36
Hình 2.12 Recency.....	37
Hình 2.13 Income_per_Family_Member_Transformed.....	38
Hình 2.14 PC1_TotalPurchases_Total.....	39
Hình 2.15 PC1_AvgPerPurchase_Income	40
Hình 2.16 Income_per_Family_Member trước và sau transform	41
Hình 2.17 Tương quan giữa các đặc trưng RFM.....	42
Hình 2.18 Kết quả scaling Age bằng StandardScaler.....	45
Hình 2.19 Kết quả scaling Dependency_Ratio bằng StandardScaler.....	45
Hình 2.20 Kết quả scaling Income bằng StandardScaler	45
Hình 2.21 Kết quả scaling Age bằng RobustScaler.....	46
Hình 2.22 Kết quả scaling Dependency_Ratio bằng RobustScaler.....	46
Hình 2.23 Kết quả scaling Income bằng RobustScaler	46
Hình 2.24 Kết quả scaling PC1_Total_TotalPurchases bằng StandardScaler.....	49
Hình 2.25 Kết quả scaling Product_HHI bằng StandardScaler.....	49
Hình 2.26 Kết quả scaling Store_Preference bằng StandardScaler.....	50
Hình 2.27 Kết quả scaling Web_Engagement bằng StandardScaler.....	50
Hình 2.28 Kết quả scaling PC1_Total_TotalPurchases bằng RobustScaler	51

Hình 2.29 Kết quả scaling Product_HHI bằng RobustScaler	51
Hình 2.30 Kết quả scaling Store_Preference bằng RobustScaler	51
Hình 2.31 Kết quả scaling Web_Engagement bằng RobustScaler	52
Hình 2.32 Kết quả scaling Income_per_Family_Member_Transformed bằng StandardScaler	55
Hình 2.33 Kết quả scaling PC1_AvgPerPurchases_Income bằng StandardScale	56
Hình 2.34 Kết quả scaling PC1_TotalPurchases_Total bằng StandardScaler	56
Hình 2.35 Kết quả scaling Recency bằng StandardScaler	56
Hình 2.36 Kết quả scaling Income_per_Family_Member_Transformed bằng RobustScaler	57
Hình 2.37 Kết quả scaling PC1_AvgPerPurchases_Income bằng RobustScaler	57
Hình 2.38 Kết quả scaling PC1_TotalPurchases_Total bằng RobustScaler	58
Hình 2.39 Kết quả scaling Recency bằng RobustScaler	58

DANH MỤC BẢNG

Bảng 2.1 Trước xử lý Missing Value	9
Bảng 2.2 Sau xử lý Missing Value	10
Bảng 2.3 Trước xử lý Duplicated Value	11
Bảng 2.4 Sau xử lý Duplicated Value	13
Bảng 2.5 Chi tiết Outliers	14
Bảng 2.6 Chi tiết nhóm Spending Outlier	15
Bảng 2.7 Chi tiết hướng xử lý cho từng loại Outliers	16
Bảng 2.8 Chuẩn hóa dữ liệu cho cột Marital Status	20
Bảng 2.9 Ưu điểm và hạn chế của xử lý Outlier	23
Bảng 2.10 Demographic trước Scaling	44
Bảng 2.11: So sánh 2 phương pháp scale với Demographic	47
Bảng 2.12 Product + Channel trước Scaling	48
Bảng 2.13 So sánh 2 phương pháp scaling với ProductChannel.....	52
Bảng 2.14 Trước scaling RFM	54
Bảng 2.15 So sánh 2 phương pháp scaling cho RFM	59

CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI

1.1. Giới thiệu bài toán

Bài báo cáo này tập trung nghiên cứu và thực nghiệm giải thuật K-Means trong bài toán Phân cụm Khách hàng – một ứng dụng quan trọng của học máy không giám sát trong lĩnh vực kinh doanh và marketing. Phân cụm khách hàng cho phép doanh nghiệp tự động phân nhóm khách hàng dựa trên sự tương đồng về đặc trưng hành vi, nhân khẩu học hoặc giá trị tiêu dùng, từ đó hỗ trợ xây dựng chiến lược chăm sóc, tiếp thị và cá nhân hóa dịch vụ hiệu quả hơn mà không cần nhãn dữ liệu có sẵn.

Tuy nhiên, việc phân cụm khách hàng đặt ra nhiều thách thức như xác định số cụm tối ưu, xử lý dữ liệu có nhiều chiều và đảm bảo tính ổn định của kết quả. Thuật toán K-Means được lựa chọn nhờ tính đơn giản, hiệu quả và khả năng mở rộng cho tập dữ liệu lớn, giúp doanh nghiệp nhanh chóng nhận diện các nhóm khách hàng tiềm năng. Thông qua việc áp dụng K-Means, báo cáo này không chỉ minh họa quy trình phân cụm mà còn đánh giá chất lượng phân cụm bằng các chỉ số thực nghiệm, từ đó làm rõ giá trị ứng dụng của học máy không giám sát trong việc hỗ trợ ra quyết định kinh doanh.

1.2. Các công trình liên quan

Bảng 1.1. Bảng giới thiệu các thuật toán

Thuật toán	Nguyên lý hoạt động	Ưu điểm	Hạn chế
K-Means	Chia dữ liệu thành K cụm bằng cách tối ưu khoảng cách giữa điểm và tâm cụm	Đơn giản, nhanh, dễ triển khai; phù hợp dữ liệu lớn	Nhạy cảm với giá trị khởi tạo; khó xử lý dữ liệu phi tuyến hoặc cụm có hình dạng phức tạp
Hierarchical Clustering	Xây dựng cây phân cấp (dendrogram) để nhóm dữ liệu theo mức độ tương đồng	Không cần xác định số cụm trước; trực quan	Tốn thời gian với dữ liệu lớn; khó mở rộng
DBSCAN	Phân cụm dựa trên mật độ điểm dữ liệu	Tìm được cụm có hình dạng bất kỳ; xử lý tốt nhiễu	Khó chọn tham số (epsilon, minPts); không tốt với dữ liệu có mật độ thay đổi
Gaussian Mixture Models (GMM)	Giả định dữ liệu được sinh từ nhiều phân phối Gaussian	Linh hoạt hơn K-Means; cho phép xác suất thuộc cụm	Tốn tài nguyên tính toán; nhạy cảm với giá trị khởi tạo

CHƯƠNG 2. CHUẨN BỊ DỮ LIỆU

2.1. Giới thiệu tập dữ liệu

Trong nghiên cứu khoa học dữ liệu, có nhiều nguồn cung cấp bộ dữ liệu phục vụ phân tích như UCI Machine Learning Repository, Kaggle hay các kho dữ liệu mở từ tổ chức, doanh nghiệp và chính phủ. Trong đề tài này, chúng ta lựa chọn bộ dữ liệu Customer Behavior, bao gồm thông tin của hơn 2.000 khách hàng. Bộ dữ liệu cung cấp cái nhìn toàn diện về đặc điểm nhân khẩu học, hành vi mua sắm và mức độ tương tác với các chiến dịch marketing.

Phân tích hành vi khách hàng là một phân tích chi tiết về nhóm khách hàng lý tưởng của một công ty. Nó giúp doanh nghiệp hiểu rõ hơn về khách hàng của mình và dễ dàng điều chỉnh sản phẩm theo nhu cầu, hành vi và mối quan tâm cụ thể của các nhóm khách hàng khác nhau.

Đây là nguồn dữ liệu mang tính thực tiễn cao, bởi nó phản ánh rõ nét chân dung tiêu dùng trong bối cảnh thương mại điện tử. Việc khai thác và phân tích bộ dữ liệu này nhằm mục tiêu phân cụm khách hàng, qua đó nhận diện các nhóm tiêu dùng khác nhau. Kết quả phân cụm không chỉ giúp doanh nghiệp tối ưu hóa chiến lược marketing, mà còn góp phần nâng cao trải nghiệm khách hàng và gia tăng hiệu quả kinh doanh.

Dataset: [Customer_Behavior.xlsx](#)

[1] Source: [Kaggle - Customer Personality Analysis Dataset](#)

```
import pandas as pd
# Đọc dữ liệu từ file CSV:
dataset = pd.read_csv(r"path_to_file", sep="\t")
# Thông tin về kiểu dữ liệu và số lượng giá trị không null
print(dataset.info())
# Kích thước của DataFrame (số dòng, số cột)
print(dataset.shape)
# Hiển thị thông tin demo về dữ liệu:
print(dataset.head(10))
# Hiển thị thông tin tổng quan về dữ liệu:
print(dataset.describe())
```

Bảng 2.1 Bảng thông tin các đặc trưng của bộ dữ liệu

#	Column	Non-Null Count	Dtype
0	ID	2240	int64
1	Year_Birth	2240	int64
2	Education	2240	object
3	Marital_Status	2240	object
4	Income	2216	float64

CHƯƠNG 2. CHUẨN BỊ DỮ LIỆU

5	Kidhome	2240	int64
6	Teenhome	2240	int64
7	Dt_Customer	2240	object
8	Recency	2240	int64
9	MntWines	2240	int64
10	MntFruits	2240	int64
11	MntMeatProducts	2240	int64
12	MntFishProducts	2240	int64
13	MntSweetProducts	2240	int64
14	MntGoldProds	2240	int64
15	NumDealsPurchases	2240	int64
16	NumWebPurchases	2240	int64

CHƯƠNG 2. CHUẨN BỊ DỮ LIỆU

17	NumCatalogPurchases	2240	int64
18	NumStorePurchases	2240	int64
19	NumWebVisitsMonth	2240	int64
20	AcceptedCmp3	2240	int64
21	AcceptedCmp4	2240	int64
22	AcceptedCmp5	2240	int64
23	AcceptedCmp1	2240	int64
24	AcceptedCmp2	2240	int64
25	Complain	2240	int64
26	Z_CostContact	2240	int64
27	Z_Revenue	2240	int64
28	Response	2240	int64

CHƯƠNG 2. CHUẨN BỊ DỮ LIỆU

- Cái nhìn tổng quan về các đặc trưng của dataset
- Dưới đây là mô tả chi tiết từng đặc trưng gốc trong dataset (29 cột). Với mỗi cột có tên cột, trạng thái null & kiểu dữ liệu, ý nghĩa, cách sử dụng, và ghi chú xử lý dữ liệu cần lưu ý.

ID	2240 non-null	int64 (Mã định danh duy nhất cho mỗi khách hàng)
Year_Birth	2240 non-null	int64 (Năm sinh khách hàng)
Education	2240 non-null	object (Trình độ học vấn (ví dụ Graduation, Master, PhD)
Marital_Status	2240 non-null	object (Tình trạng hôn nhân (Single, Married, Together, Divorced, v.v.).
Income	2216 non-null	float64 (Thu nhập hộ gia đình (số tiền).
Kidhome	2240 non-null	int64 (Số trẻ con sống cùng (kid at home).
Teenhome	2240 non-null	int64 (Số thiếu niên sống cùng) .
Dt_Customer	2240 non-null	object (Ngày khách hàng trở thành khách hàng (ngày đăng ký))
Recency	2240 non-null	int64 (Số ngày kể từ lần mua hàng gần nhất)
MntWines	2240 non-null	int64 (Tổng chi tiêu cho rượu vang trong khoảng thời gian khảo sát)
MntFruits	2240 non-null	int64(Tổng chi tiêu cho trái cây)
MntMeatProducts	2240 non-null	int64(Tổng chi tiêu cho thịt)
MntFishProducts	2240 non-null	int64(Tổng chi tiêu cho sản phẩm cá)
MntSweetProducts	2240 non-null	int64(Tổng chi tiêu cho đồ ngọt)

CHƯƠNG 2. CHUẨN BỊ DỮ LIỆU

MntGoldProds	2240 non-null	int64(Tổng chỉ tiêu cho sản phẩm cao cấp/kim loại (gold products)).
NumDealsPurchases	2240 non-null	int64(Số lần mua hàng có dùng khuyến mãi/giảm giá)
NumWebPurchases	2240 non-null	int64(Số lần mua qua website)
NumCatalogPurchases	2240 non-null	int64(Số lần mua qua catalogue)
NumStorePurchases	2240 non-null	int64(Số lần mua trực tiếp tại cửa hàng)
NumWebVisitsMonth	2240 non-null	int64(Số lần truy cập website trong tháng gần nhất)
AcceptedCmp3	2240 non-null	int64 (0/1)(Khách có chấp nhận chiến dịch marketing số 3 không)
AcceptedCmp4	2240 non-null	int64 (0/1)(Nhận chiến dịch số 4)
AcceptedCmp5	2240 non-null	int64 (0/1)(Nhận chiến dịch số 5)
AcceptedCmp1	2240 non-null	int64 (0/1)(Nhận chiến dịch số 1)
AcceptedCmp2	2240 non-null	int64 (0/1)(Nhận chiến dịch số 2).
Complain	2240 non-null	int64 (0/1)(Khách hàng có từng khiếu nại không.)
Z_CostContact	2240 non-null	int64(Biến nội bộ liên quan chi phí contact campaign (bình thường là mã hóa/biến dụng))
Z_Revenue	2240 non-null	int64(Biến nội bộ liên quan revenue từ contact; có thể là mã nhóm revenue)
Response	2240 non-null	int64 (0/1)(Khách có phản hồi chiến dịch gần nhất hay không (thông thường 1 = có))

2.2. Tiền xử lý dữ liệu

2.2.1. Giá trị thiếu

a) Vấn đề đang tồn tại

Phát hiện: 1 cột có giá trị bị thiếu

Tổng số missing values: 24 giá trị

Tỷ lệ ảnh hưởng: ~1.07% tổng số dòng (24/2,240 dòng)

Cột bị ảnh hưởng: Income

Bảng 2.2 Trước xử lý Missing Value

Thông số	Giá trị
Dataset gốc	2,240 dòng × 29 cột
Cột bị thiếu	Income
Missing cells	24 cells
Tỷ lệ overall	0.04%
Cột có missing	1/29 cột (3.45%)

b) Nhận xét và phương án xử lý

Qua phân tích, dữ liệu bị thiếu chỉ xuất hiện ở một cột duy nhất là Income, với tổng cộng 24 giá trị thiếu trên 2.240 dòng, chiếm tỷ lệ rất nhỏ so với toàn bộ tập dữ liệu (khoảng 0.04%).

Do đó, nhóm lựa chọn loại bỏ các dòng chứa giá trị thiếu thay vì thực hiện các phương pháp bù (imputation). Quyết định này dựa trên các yếu tố sau:

- Tỷ lệ thiếu thấp: đảm bảo việc loại bỏ không làm suy giảm đáng kể kích thước mẫu.
- Phân bố missing tập trung: Chỉ ảnh hưởng một cột, không gây mất cân bằng dữ liệu.
- Tính chất biến: Income là biến liên tục, việc ước lượng giá trị thay thế có thể làm sai lệch phân tích.

- Mục tiêu nghiên cứu: Đảm bảo chất lượng dữ liệu cho mô hình phân cụm, tránh nhiễu từ giá trị giả định.

c) Kết quả xử lý

Bảng 2.3 Sau xử lý Missing Value

Thông tin	Giá trị
Dataset gốc	2,240 dòng
Dòng có missing values	24 dòng
Dataset sau loại bỏ	2,216 dòng
Tỷ lệ dữ liệu còn lại	98.93%
Missing values còn lại	0

d) Tổng kết

Đơn giản, minh bạch: Dễ hiểu, dễ tái tạo

Bảo toàn chất lượng: Không tạo ra dữ liệu giả (synthetic data)

An toàn: Tỷ lệ mất dữ liệu → không ảnh hưởng statistical power

Do tỷ lệ giá trị thiếu rất thấp ($\approx 0.04\%$) và chỉ tập trung ở một biến liên tục, phương pháp loại bỏ các dòng thiếu được lựa chọn nhằm đảm bảo tính toàn vẹn và chất lượng dữ liệu cho mô hình phân cụm, đồng thời tránh sai lệch do ước lượng giá trị giả định.

2.2.2. Giá trị trùng lặp

a) Vấn đề đang tồn tại

Tổng dòng: 2,216

Feature duplicates phát hiện: 182 dòng ($\approx 8.21\%$)

Số nhóm duplicate: 176 nhóm

Phân bố kích thước nhóm:

- Nhóm size 2: 170 nhóm (340 dòng)
- Nhóm size 3: 6 nhóm (18 dòng)

Bảng 2.4 Trước xử lý Duplicated Value

Loại Duplicate	Số lượng	Tỷ lệ	Mô tả
Full-row	0	0%	Không có dòng trùng lặp hoàn toàn
Feature-level	182	8.13%	Khách hàng khác nhau nhưng đặc trưng giống hệt
ID duplicates	0	0%	Không có ID trùng lặp

b) Nhận xét và phương án xử lý

Qua phân tích, dữ liệu không xuất hiện dòng trùng lặp hoàn toàn (Full-row) và không có ID trùng lặp, đảm bảo tính duy nhất của khóa định danh. Tuy nhiên, có 182 dòng ($\approx 8.21\%$) xuất hiện trùng lặp ở mức đặc trưng (Feature-level), tức là các khách hàng khác nhau nhưng có đặc trưng giống hệt. Hiện tượng này có thể gây ảnh hưởng đến quá trình phân cụm, làm giảm độ phân biệt giữa các nhóm và dẫn đến kết quả thiếu chính xác.

Để đảm bảo chất lượng dữ liệu cho mô hình K-Means, nhóm lựa chọn loại bỏ các bản ghi trùng lặp ở mức đặc trưng. Phương án này dựa trên các yếu tố sau:

- Giảm nhiễu và bias: Loại bỏ các dòng trùng lặp giúp mô hình phân cụm phản ánh sự đa dạng thực tế của dữ liệu.
- Đảm bảo tính đại diện: Tránh việc một nhóm khách hàng bị lặp lại nhiều lần, gây thiên lệch trong tính toán tâm cụm.
- Tối ưu hiệu suất: Giảm kích thước dữ liệu, rút ngắn thời gian huấn luyện mà không làm mất thông tin quan trọng.

c) Kết quả xử lý

Bảng 2.5 Sau xử lý Duplicated Value

Thông tin	Giá trị
Dataset ban đầu	2,216 dòng
Feature duplicates bị loại bỏ	182 dòng
Dataset sau xử lý	2,034 dòng
Tỷ lệ dữ liệu còn lại	91.79%
Số nhóm duplicate loại bỏ	176 nhóm

d) Tổng kết

Do tỷ lệ trùng lặp ở mức đặc trưng khá đáng kể ($\approx 8.21\%$), việc loại bỏ 182 dòng trùng lặp giúp đảm bảo tính đa dạng và đại diện của dữ liệu, giảm thiên lệch trong tính toán tâm cụm và nâng cao độ chính xác của mô hình K-Means. Sau xử lý, tập dữ liệu còn 2,034 dòng, đủ lớn để duy trì thống kê và hiệu quả phân cụm.

2.2.3. Giá trị ngoại lai

a) Vấn đề đang tồn tại

Bảng 2.6 Chi tiết Outliers

Nhóm thuộc tính	Chỉ số	Nội dung
Income Outliers	Giá trị nghi vấn	1 giá trị
	Chi tiết	666,666 ($\geq$ ngưỡng 500,000)
	Khoảng IQR	[5,250; 105,000]
	Đánh giá	Đây có thể là lỗi nhập liệu hoặc trường hợp khách hàng có thu nhập cực kỳ cao, gây sai lệch cho phân tích.
Year_Birth Outliers	Giá trị bất thường	2 giá trị
	Chi tiết	[1893, 1899]
	Độ tuổi tương ứng	~131 và ~125 tuổi (không thực tế)
	Đánh giá	Đây là vấn đề chất lượng dữ liệu, có khả năng do lỗi nhập liệu hoặc dữ liệu không được kiểm soát.
Count Outliers	NumWebPurchases	4 outliers
	NumCatalogPurchases	4 outliers
	NumDealsPurchases	24 outliers
	NumWebVisitsMonth	3 outliers

– Spending Outliers (chi tiết 6 biến):

Bảng 2.7 Chi tiết nhóm Spending Outlier

Biến	Outliers	Tỷ lệ	IQR Upper Bound	Top Extreme
MntFruits	96	4.28%	79.5	[199, 199, 199]
MntSweetProducts	105	4.69%	79.5	[263, 263, 262]
MntFishProducts	72	3.21%	142.5	[259, 259, 259]
MntGoldProds	49	2.19%	118.5	[362, 321, 321]
MntMeatProducts	29	1.29%	619.5	[1725, 1725, 1725]
MntWines	1	0.04%	1018.5	[1493]

b) Nhận xét và phương án xử lý

Nhóm không loại bỏ toàn bộ các giá trị ngoại lai mà sẽ dựa trên ngữ cảnh kinh tế và tính hợp lý của dữ liệu để đánh giá. Chỉ những giá trị thực sự cực đoan, không phản ánh thực tế (ví dụ: lỗi nhập liệu hoặc vượt xa ngưỡng hợp lý) mới bị loại bỏ. Các outliers hợp lý về mặt kinh doanh sẽ được giữ lại nhằm bảo toàn thông tin quan trọng cho phân tích.

Bảng 2.8 Chi tiết hướng xử lý cho từng loại Outliers

Outliers	Xử lý	Lý do
Income $\geq$ 500K	Loại bỏ	Giá trị nghi vấn, có thể là lỗi nhập liệu
Year_Birth < 1900	Loại bỏ	Không thực tế, khách hàng quá già
Spending outliers (352)	Giữ lại	Hợp lệ – phản ánh khách hàng chi tiêu cao
Count outliers (35)	Giữ lại	Hợp lệ – hành vi mua sắm đặc biệt

– Chi tiết Outliers được giữ lại (387 records):

- Spending Outliers (352)
 - Business-valid: Khách VIP/high-spender phân khúc quan trọng
 - Clustering value: Cần phân biệt giữa low/medium/high spenders
 - IQR reasonable: Upper bounds hợp lý, không quá cực đoan
- Count Outliers (35)
 - Behavioral insight: Phản ánh hành vi mua sắm đa dạng
 - Low impact: Chỉ chiếm 1.56%, không ảnh hưởng phân phối chung
 - Marketing value: Khách hàng frequent buyer cần nhận diện

c) Kết quả xử lý

Sau khi phân tích 390 giá trị ngoại lai trên 25 biến, nhóm áp dụng phương pháp loại bỏ có chọn lọc dựa trên ngữ cảnh kinh tế và tính hợp lý của dữ liệu. Các outliers hợp lý về mặt kinh doanh được giữ lại để bảo toàn thông tin quan trọng, chỉ loại bỏ những giá trị cực đoan không phản ánh thực tế (ví dụ: lỗi nhập liệu hoặc vượt xa ngưỡng hợp lý).

- Tóm tắt kết quả:
 - Tổng outliers phát hiện: 390 giá trị
 - Loại bỏ:
 - $\text{Income} \geq 500\text{K}$: 1 dòng
 - $\text{Year_Birth} < 1900$: 2 dòng
 - Tổng số dòng bị loại bỏ: 3 dòng ($\approx 0.15\%$)

Dataset sau xử lý: 2,031 dòng (giữ lại 99.85% dữ liệu)

d) Tổng kết

Sau xử lý, dữ liệu giảm từ 2,034 xuống 2,031 dòng, giữ lại 99.85% dữ liệu, đồng thời bảo toàn 387 outliers hợp lệ ($\approx 19.05\%$) phản ánh hành vi kinh doanh quan trọng như VIP customers và frequent buyers. Việc giữ lại các outliers này giúp mô hình phân cụm nhận diện phân khúc giá trị cao, phục vụ chiến lược marketing.

- Ưu điểm:
 - Đảm bảo chất lượng dữ liệu nhưng vẫn giữ insight kinh doanh.
 - Bảo toàn gần như toàn bộ dữ liệu (99.85%).
 - Tối ưu cho phân cụm khách hàng.
- Hạn chế:
 - Vẫn còn 387 outliers hợp lệ, phân phối chi tiêu lệch phải
→ cần chuẩn hóa mạnh hơn (RobustScaler, log transform).

2.2.4. Chuẩn hóa dữ liệu phân loại

a) Vấn đề đang tồn tại

- Marital_Status: Phân tích cho thấy biến này có các giá trị chính: Married, Together, Single, Divorced, Widow. Tuy nhiên, xuất hiện một số giá trị không chuẩn:
 - Alone và YOLO: trùng nghĩa với Single nhưng dùng từ không thống nhất.
 - Absurd: giá trị vô nghĩa, không có ý nghĩa nghiệp vụ.
Những vấn đề này dẫn đến sự không nhất quán và cần được chuẩn hóa để đảm bảo tính chính xác trong phân cụm.
- Education: Các giá trị gồm Graduation, PhD, Master, 2n Cycle, Basic. Tất cả đều hợp lệ và có thứ tự logic, không cần xử lý thêm.
- Dt_Customer: Biến này chứa dữ liệu dạng chuỗi ngày (DD-MM-YYYY). Cần chuyển đổi sang kiểu datetime để phục vụ phân tích, nhưng không yêu cầu chuẩn hóa giá trị.

b) Phương án xử lý

- Chuẩn hóa Marital_Status: gộp các giá trị không chuẩn về nhóm hợp lý `
- Giữ nguyên Education vì đã chuẩn.
- Chuyển đổi Dt_Customer sang định dạng ngày để thuận tiện cho tính

c) Kết quả xử lý

- Trước khi xử lý:
 - Số lượng giá trị duy nhất: 8
 - Giá trị không chuẩn/slang: 3 (Alone, YOLO, Absurd)
 - Số bản ghi bị ảnh hưởng: 7 ($\approx 0.34\%$)
- Mapping áp dụng:
 - Alone $\rightarrow$ Single (3 giá trị)
 - YOLO $\rightarrow$ Single (2 giá trị)
 - Absurd $\rightarrow$ Other (2 giá trị)
- Sau khi xử lý:
 - Số lượng giá trị duy nhất: 6
 - Tất cả giá trị đã được chuẩn hóa
 - Tính toàn vẹn dữ liệu được bảo đảm

d) Tổng kết

- Lợi ích đạt được:
 - Đảm bảo tính nhất quán về ngữ nghĩa, loại bỏ sự trùng lặp ý nghĩa (Alone, YOLO $\rightarrow$ Single).
 - Chuẩn hóa giá trị không chuẩn, giảm nhiễu từ các nhóm hiếm.
 - Dữ liệu sẵn sàng cho bước mã hóa và mô hình hóa.

- Phân tích tác động:

Bảng 2.9 Chuẩn hóa dữ liệu cho cột Marital Status

Chỉ số	Trước	Sau	Cải thiện
Số lượng category	8	6	Giảm 25% độ phức tạp
Giá trị không nhất quán	7	0	Đã xử lý
Tần suất nhóm Single	23.2%	23.4%	Tăng hợp lý

- Kết luận:

Quá trình chuẩn hóa đã hợp nhất các giá trị không chuẩn, giảm từ 8 xuống 6 nhóm, xử lý 100% giá trị không nhất quán (0.34% dữ liệu). Kết quả đảm bảo tính nhất quán cho biến phân loại, giúp dữ liệu sẵn sàng cho bước mã hóa và mô hình phân cụm.

2.2.5. Chuyển đổi kiểu dữ liệu và mã hóa

a) Vấn đề đang tồn tại

- Type Conversion Issue:
 - Biến Dt_Customer hiện ở dạng chuỗi (object) với định dạng DD-MM-YYYY.
 - Vấn đề: Không thể tính toán các đặc trưng thời gian (tenure, recency), không thể sắp xếp theo timeline, và không thể trích xuất thành phần ngày/tháng/năm.
- Encoding Issues:
 - Education: Là biến ordinal (có thứ tự) nhưng đang ở dạng chuỗi. Nếu dùng One-Hot Encoding sẽ mất thông tin thứ bậc.
 - Marital_Status: Là biến nominal (không thứ tự), có 6 giá trị, trong đó một số nhóm hiếm (<1%). Cần mã hóa để mô hình hiểu được.

b) Nhận xét và phương án xử lý

- Datetime Conversion: Chuyển đổi Dt_Customer từ object sang datetime64[ns] với định dạng chuẩn %d-%m-%Y.
- Education Encoding (Ordinal): Áp dụng Ordinal Encoding, ánh xạ thứ tự từ thấp đến cao: Basic → 2n Cycle → Graduation → Master → PhD. Tạo cột mới Education_ord với giá trị số từ 0 đến 4.
- Marital_Status Encoding (Nominal): Áp dụng One-Hot Encoding kết hợp nhóm các giá trị hiếm (<1%) vào nhóm “Other” để giảm độ phức tạp. Tạo 6 cột dummy dạng uint8 để tối ưu bộ nhớ.

c) Kết quả xử lý

- Dt_Customer: Chuyển đổi thành công sang datetime64[ns], không có lỗi parsing.
- Education: Tạo cột Education_ord (Int64), giữ nguyên thứ tự logic, không mất dữ liệu.
- Marital_Status: Tạo 6 cột dummy (Marital_*), nhóm giá trị hiếm về “Other”, sử dụng kiểu uint8 để tiết kiệm bộ nhớ.

d) Tổng kết

- Đảm bảo tính toàn vẹn dữ liệu: Đã chuyển đổi thành công, không mất thông tin.
- Tối ưu cho mô hình học máy: Biến ordinal được mã hóa giữ thứ tự, biến nominal được mã hóa one-hot và giảm độ phức tạp nhờ nhóm giá trị hiếm.
- Hỗ trợ phân tích nâng cao: Dt_Customer ở dạng datetime cho phép tính toán đặc trưng thời gian.
- Hiệu quả bộ nhớ: Dummy variables sử dụng uint8, tiết kiệm ~87.5% so với kiểu mặc định.

2.2.6. Tổng kết

a) Tình trạng trước tiền xử lý

- Kích thước: 2,240 dòng $\times$ 29 cột
- Kiểu dữ liệu: Chủ yếu là số nguyên (int64), một số cột dạng chuỗi (object) và một cột dạng số thực (float64).
- Vấn đề chính:
 - Giá trị thiếu: 24 giá trị, tất cả nằm ở cột Income.
 - Trùng lặp: Không có dòng trùng lặp hoàn toàn, nhưng có 182 dòng trùng lặp về đặc trưng.
 - Ngoại lai: 390 giá trị, gồm 1 giá trị thu nhập cực lớn (666,666), 2 giá trị năm sinh không thực tế (<1900), và nhiều giá trị chi tiêu cao.
 - Không nhất quán: Một số giá trị trong Marital_Status không chuẩn (Alone, YOLO, Absurd).
 - Kiểu dữ liệu chưa phù hợp: Dt_Customer ở dạng chuỗi, Education chưa thể hiện thứ bậc.

b) Tình trạng sau tiền xử lý

- Kích thước: 2,010 dòng $\times$ 24 cột (giảm 10.27%).
- Các bước thực hiện:
 - Loại bỏ 24 dòng có giá trị thiếu và 182 dòng trùng lặp đặc trưng.
 - Loại bỏ 3 outliers cực đoan, giữ lại 387 outliers hợp lệ để bảo toàn thông tin kinh doanh.
 - Chuẩn hóa Marital_Status và mã hóa bằng One-Hot Encoding
 - Mã hóa Education theo thứ tự (Ordinal Encoding).
 - Chuyển đổi Dt_Customer sang định dạng ngày (datetime64).
- Kết quả: Không còn giá trị thiếu, không còn trùng lặp, dữ liệu nhất quán và sẵn sàng cho mô hình hóa.

c) Đánh giá chất lượng tiền xử lý

- Chất lượng dữ liệu: Được cải thiện rõ rệt, loại bỏ hoàn toàn missing values và duplicates.
- Bảo toàn thông tin: Giữ lại các outliers hợp lệ để phục vụ phân tích phân khúc khách hàng.

Bảng 2.10 Ưu điểm và hạn chế của xử lý Outlier

Ưu điểm	Hạn chế
Giữ lại thông tin quan trọng về khách hàng chi tiêu cao	Phân phối dữ liệu vẫn lệch phải, cần chuẩn hóa thêm
Loại bỏ triệt để dữ liệu thiếu và trùng lặp	Mất một phần nhỏ dữ liệu do loại bỏ missing values
Quy trình rõ ràng, dễ tái lập	Ngưỡng loại bỏ outliers có thể cần điều chỉnh cho bộ dữ liệu khác

d) Hướng xử lý khác

Ngoài phương pháp hiện tại (loại bỏ giá trị thiếu và outliers cực đoan), có thể xem xét hai hướng tiếp cận bổ sung:

- Bảo toàn dữ liệu tối đa : Thay vì loại bỏ 24 dòng có Income bị thiếu, có thể điền giá trị thay thế.

– Phương pháp:

- Điền giá trị trung bình hoặc trung vị.
- Dự đoán bằng mô hình hồi quy dựa trên các biến liên quan (Education, Year_Birth).

– Ưu điểm: Giữ nguyên số lượng khách hàng, không mất dữ liệu.

– Nhược điểm: Có thể làm sai lệch phân phối gốc do giá trị giả định. Xử lý outliers mạnh hơn

⇒ Thay vì chỉ loại bỏ 3 outliers cực đoan, có thể biến đổi các biến có phân phối lệch để giảm tác động của 387 outliers còn lại.

– Phương pháp:

- Log Transformation: Áp dụng biến đổi logarit cho các biến chi tiêu và thu nhập để giảm độ lệch.
- Robust Scaling: Chuẩn hóa dựa trên trung vị và IQR, ít bị ảnh hưởng bởi outliers.

– Ưu điểm: Giúp thuật toán dựa trên khoảng cách (như K-Means) hoạt động hiệu quả hơn, cụm rõ ràng hơn.

– Nhược điểm: Làm mất ý nghĩa trực tiếp của giá trị gốc, khó diễn giải về mặt kinh doanh.

▪ Kết luận

Quy trình xử lý hiện tại đạt sự cân bằng giữa làm sạch dữ liệu và giữ lại giá trị kinh doanh. Dữ liệu sau xử lý có chất lượng cao, nhất quán và phù hợp cho bài toán phân cụm khách hàng. Các phương pháp bổ sung như imputation hoặc biến đổi dữ liệu (log transform, robust scaling) có thể được xem xét ở giai đoạn tiếp theo để tối ưu hơn cho mô hình.

2.3. Xây dựng đặc trưng

Sau khi có được bộ dữ liệu đã làm sạch, chúng ta bước vào giai đoạn Xây dựng Đặc trưng. Mục tiêu chính của giai đoạn này không phải là tạo ra một bộ dữ liệu duy nhất, mà là tách và phát triển ba bộ đặc trưng riêng biệt, mỗi bộ được thiết kế để trả lời một câu hỏi kinh doanh cụ thể thông qua phân cụm:

- Phân Cụm Nhân Khẩu Học (Demographic): "Khách hàng là ai?"
 - Tập trung: Các đặc điểm về vòng đời, tuổi tác, và cấu trúc gia đình.
 - Hành động: Tạo ra các biến như Age, Life_Stage (Giai đoạn sống), và Dependency_Ratio (Tỷ lệ phụ thuộc tài chính).
- Phân Cụm Hành Vi Mua Sắm (Product & Channel): "Khách hàng mua sắm như thế nào?"
 - Tập trung: Thói quen mua sắm, sự đa dạng sản phẩm và kênh tương tác ưa thích.
 - Hành động: Tạo các biến như Total_Spent, Product_HHI (mức độ đa dạng sản phẩm), và Store_Preference (mức độ ưa thích mua tại cửa hàng).
- Phân Cụm Giá Trị (RFM): "Khách hàng mang lại giá trị bao nhiêu?"
 - Tập trung: Giá trị kinh tế mà khách hàng mang lại.
 - Hành động: Xây dựng các biến dựa trên mô hình RFM (Recency, Frequency, Monetary) mở rộng và kết hợp với các chỉ số tài chính như Income và AvgPerPurchase.

2.3.1. Feature Engineering


a) Demographic Feature Engineering

- Tổng quan

Bước Feature Engineering cho chiến lược Demographic Clustering tập trung vào việc xây dựng 5 biến đặc trưng từ dữ liệu gốc, trong đó 3 biến dùng trực tiếp cho phân cụm K-Means và 2 biến dành cho phân tích hậu kiểm (post-hoc analysis). Cách tiếp cận này đảm bảo rằng các yếu tố nhân khẩu học được phản ánh một cách toàn diện mà không gây ra hiện tượng dominance.


- Các đặc trưng được tạo:

- Age (Tuổi khách hàng)
 - Được tính toán từ Year_Birth với công thức: $2014 - \text{Year_Birth}$
 - Phạm vi: 18-100 tuổi
 - Skewness ban đầu: 0.137
 - Đặc điểm: Phân phối gần như chuẩn, giữ nguyên không biến đổi.




Hình 2.1 Phân phối Age

- Income (Thu nhập hàng năm)
 - Đặc trưng gốc từ dataset
 - Skewness: 0.367
 - Đặc điểm: Thu nhập dao động từ 1,730 đến 162,397 đơn vị, phân phối tương đối cân bằng



Hình 2.2 Phân phối Income

- Dependency_Ratio (Tỷ lệ phụ thuộc gia đình)
 - Công thức: $(\text{TotalChildren} \times 10,000) / \text{Income_per_Family_Member}$
 - Skewness ban đầu: 1.735 (vượt ngưỡng 0.5, cần biến đổi)
 - Transform áp dụng: Yeo-Johnson (do có 568 giá trị = 0, chiếm 28.3%)
 - Kết quả: Skewness giảm từ 1.735 xuống 0.089
 - Ý nghĩa: Đo mức độ phụ thuộc tài chính của các thành viên gia đình vào thu nhập



Hình 2.3 Phân phối của Dependency_Ratio


- Education_ord (Trình độ giáo dục - Ordinal)
 - Mã hóa: 0 (Basic) → 4 (PhD), có 5 mức độ
 - Không dùng cho K-Means để tránh hiệu ứng dominance của biến ordinal
- Life_Stage (Giai đoạn cuộc sống - Categorical)
 - 5 nhóm: Young Single (451), Young Family (525), Mature Family (321), Empty Nest (223), Single Parent (490)
 - Được xây dựng từ: $\text{Age} \times \text{TotalChildren} \times \text{Marital_Status}$

- Phương pháp biến đổi:

Hệ thống tự động phát hiện phương pháp biến đổi tối ưu đặc tính trên dữ liệu:


- Box-Cox: Được áp dụng cho dữ liệu thuần dương ($\min > 0$)
- Yeo-Johnson: Được áp dụng cho dữ liệu có giá trị 0 hoặc âm

Trong trường hợp này, chỉ Dependency_Ratio cần biến đổi vì có skewness = 1.735. Yeo-Johnson được chọn vì biến này chứa nhiều giá trị 0 (28.3%), biểu thị các gia đình không có con cái.



Hình 2.4 Phân phối của Dependency_Ratio trước và sau transform

- Phân tích tương quan
 - Giữa 3 biến clustering:
 - Age ↔ Income: $r = 0.201$
 - Age ↔ Dependency_Ratio: $r = -0.043$
 - Income ↔ Dependency_Ratio: $r = -0.601$



Hình 2.5 Tương quan giữa các đặc trưng Demographic

- Kết luận: Dataset Demographic sẵn sàng với 3 biến được tinh chỉnh:
 - 3 biến clustering có độc lập cao, phân phối chuẩn hóa tốt
 - Không có vấn đề dữ liệu hoặc Multicollinearity (Đa cộng tuyến – xảy ra khi từ 3 biến độc lập trở lên có mối quan hệ tuyến tính mạnh mẽ với nhau)

Dataset: [Customer_Behavior_Demographic.xlsx](#)


b) Product + Channel Feature Engineering

– Tổng quan

Bước Feature Engineering cho chiến lược Product + Channel Clustering tập trung vào hành vi mua sắm của khách hàng thông qua lăng kính "mua bao nhiêu" thay vì "mua cái gì". Kết quả là 4 biến clustering độc lập cao và 8 biến tham chiếu để phân tích hậu kiểm.


– Các biến được tạo

- Product_HHI (Mức độ tập trung sản phẩm)
 - Công thức: $\sum(\text{Preference}_{(i)})^2$ cho 6 loại sản phẩm
 - Phạm vi: 0.167 - 1
 - ⇒ Ý nghĩa: Giá trị cao = khách hàng chuyên mua 1 loại, giá trị thấp = đa dạng sản phẩm




Hình 2.6 Product_HHI

- Store_Preference (Ưu tiên kênh cửa hàng)
 - Công thức: $\text{NumStorePurchases} / \text{TotalPurchases}$
 - Phạm vi: 0-1 (không biến đổi, skewness = 0.059)
 - Ý nghĩa: Tỷ lệ mua tại cửa hàng vật lý so với online.




Hình 2.7 Store_Preference

- Web_Engagement (Hành vi truy cập)
 - Dữ liệu: NumWebVisitsMonth (số lần truy cập web hàng tháng)
 - Phạm vi: 0-20 (không biến đổi, skewness = 0.279)
 - Ý nghĩa: Mức độ tương tác với nền tảng số




Hình 2.8 Web_Engagement

- PC1_Total_TotalPurchases (Tổng hợp PCA)
 - Biến gốc 1: Total_Spent_Transformed (Box-Cox: skew 0.857 → -0.126)
 - Biến gốc 2: TotalPurchases (skewness = 0.249, không cần biến đổi)
 - Tương quan gốc: $r = 0.874$ (cần PCA)
 - Kết quả PCA: Giữ lại 93.69% phương sai từ 2 biến
 - Công thức: $0.7071 \times \text{Total_Spent_Transformed} + 0.7071 \times \text{TotalPurchases}$
 - Ý nghĩa: Biến tổng hợp đo khối lượng chi tiêu và tần suất mua hàng



Hình 2.9 PC1_TotalPurchases

- Wine_Preference: Tỷ lệ chi tiêu vào rượu vang.
- Meat_Preference: Tỷ lệ chi tiêu vào thịt.
- Fish_Preference: Tỷ lệ chi tiêu vào cá.
- Fruit_Preference: Tỷ lệ chi tiêu vào trái cây.
- Sweet_Preference: Tỷ lệ chi tiêu vào bánh ngọt.
- Gold_Preference: Tỷ lệ chi tiêu vào sản phẩm vàng.
- Dominant_Product: Loại sản phẩm được mua nhiều nhất.
- Top_Product_Share: Tỷ lệ chi tiêu cho sản phẩm chủ yếu.




Hình 2.10 Các đặc trưng tham chiếu

- Phương pháp biến đổi
- Total_Spent Transform
 - Phương pháp: Box-Cox (vì dữ liệu thuần dương, không có giá trị 0)
 - Lambda: 0.185
 - Kết quả: Skewness giảm từ 0.857 xuống -0.126 (cải thiện 0.731)
- PCA Reduction
 - Total_Spent_Transformed ↔ TotalPurchases có $r = 0.874 \geq 0.7$
 - Áp dụng: PCA giữ 1 thành phần chính
 - Lợi ích: Loại bỏ multicollinearity, giảm từ 5 biến xuống 4 biến clustering
 - Kết quả: PC1 giải thích 93.69% phương sai từ 2 biến tương quan cao

– Phân tích tương quan

- Product_HHI ↔ Store_Preference: $r = -0.08$
- Product_HHI ↔ Web_Engagement: $r = 0.06$
- Product_HHI ↔ PC1: $r = 0.20$
- Store_Preference ↔ Web_Engagement: $r = -0.20$
- Store_Preference ↔ PC1: $r = -0.29$
- Web_Engagement ↔ PC1: $r = -0.40$



Hình 2.11 Tương quan giữa các đặc trưng Product Channel

– Kết Luận

Dataset Product+Channel đã được tinh chỉnh thành công với 4 biến clustering độc lập cao, kết hợp khối lượng mua sắm, tần suất, đa dạng sản phẩm, và kênh phân phối. 8 biến tham chiếu cung cấp bối cảnh chi tiết để diễn giải các cluster được hình thành, sẵn sàng cho bước K-Means Clustering.

Dataset: [Customer_Behavior_ProductChannel.xlsx](#)


c) RFM Feature Engineering

– Tổng quan :

Bước Feature Engineering cho chiến lược RFM Clustering tập trung vào phân khúc khách hàng dựa trên giá trị kinh tế thông qua ba chỉ số chính: Recency (tần suất gần đây), Frequency (tần suất giao dịch), và Monetary (giá trị chi tiêu). Kết quả là 4 biến clustering độc lập cao (sau khi áp dụng PCA giảm chiều từ 6 biến ban đầu).


– Các biến được tạo:

- Recency (Tần suất gần đây)
 - Dữ liệu gốc: Days_Since_Last_Purchase
 - Phạm vi: 0-100 ngày (không biến đổi, skewness = giá trị nhỏ)
 - Ý nghĩa: Số ngày kể từ lần mua hàng gần nhất. Giá trị cao = khách hàng không hoạt động
 - Độc lập cao: Recency không tương quan với các biến khác ($r < 0.01$)




Hình 2.12 Recency

- Income_per_Family_Member_Transformed (Khả năng tài chính)
 - Công thức: $\text{Income} / (2 + \text{TotalChildren})$
 - Biến đổi: Box-Cox (vì dữ liệu thuần dương)
 - Skewness: 1.003 $\rightarrow$ -0.006 (cải thiện 0.997)
 - Ý nghĩa: Thu nhập bình quân trên đầu người trong gia đình




Hình 2.13 Income_per_Family_Member_Transformed

- PC1_TotalPurchases_Total (Tổng hợp PCA)
 - Biến gốc 1: TotalPurchases (tần suất = 14.89, skewness = 0.249)
 - Biến gốc 2: Total_Spent (giá trị = 608, skewness = 0.857 → -0.126 sau transform)
 - Tương quan gốc: $r = 0.756$ (cần PCA)
 - Kết quả PCA: Giữ lại 87.81% phương sai từ 2 biến
 - Công thức: $0.7071 \times \text{TotalPurchases} + 0.7071 \times \text{Total_Spent}$
 - Ý nghĩa: Biến tổng hợp đo khối lượng mua hàng



Hình 2.14 PC1_TotalPurchases_Total


- PC1_AvgPerPurchase_Income (Tổng hợp PCA)
 - Biến gốc 1: AvgPerPurchase_Transformed
 - Biến gốc 2: Income (Thu nhập cơ bản)
 - Tương quan gốc: $r = 0.795$ (cần PCA)
 - Kết quả PCA: Giữ lại 89.73% phương sai từ 2 biến
 - Công thức: $0.7071 \times \text{AvgPerPurchase_Transformed} + 0.7071 \times \text{Income}$
 - Ý nghĩa: Biến tổng hợp đo sức mua (kết hợp AOV + khả năng tài chính)



Hình 2.15 PC1_AvgPerPurchase_Income

CHƯƠNG 2. CHUẨN BỊ DỮ LIỆU

- Phương pháp biến đổi:
- AvgPerPurchase Transform
 - Phương pháp: Yeo-Johnson (vì có giá trị = 0, chiếm 0.2%)
 - Lambda: 0.079
 - Kết quả: Skewness giảm từ 1.315 xuống -0.020 (cải thiện 1.295)
- Income_per_Family_Member Transform
 - Phương pháp: Box-Cox (dữ liệu thuần dương)
 - Lambda: 0.206
 - Kết quả: Skewness giảm từ 1.003 xuống -0.006 (cải thiện 0.997)




Hình 2.16 Income_per_Family_Member trước và sau transform

– Phân tích tương quan:

Giữa 4 biến clustering sau PCA:

- Recency ↔ Income_per_Family_Member_Tr: $r = -0.01$
- Recency ↔ PC1_TotalPurchases_Total: $r = 0.01$
- Recency ↔ PC1_AvgPerPurchase_Income: $r = 0.01$
- Income_per_Family_Member_Tr ↔ PC1_TotalPurchases_Total: $r = 0.76$
- Income_per_Family_Member_Tr ↔ PC1_AvgPerPurchase_Income: $r = 0.93$
- PC1_TotalPurchases_Total ↔ PC1_AvgPerPurchase_Income: $r = 0.87$



Hình 2.17 Tương quan giữa các đặc trưng RFM

– Kết Luận

Dataset RFM đã được xây dựng thành công với 4 biến clustering tối ưu hóa, trong đó:

- Recency độc lập hoàn toàn từ các biến khác
- Income_per_Family_Member_Transformed đo khả năng tài chính
- PC1_TotalPurchases_Total đo khối lượng giao dịch
- PC1_AvgPerPurchase_Income đo sức mua

⇒ Mặc dù các PC có tương quan cao với nhau, nhưng điều này là tự nhiên do bản chất RFM.

Dataset: [Customer_Behavior_RFM.xlsx](#)

2.3.2. Feature Scaling

– Tổng quan

Tiếp nối quá trình tiền xử lý và xây dựng đặc trưng, bước này tập trung vào Feature Scaling – một yêu cầu quan trọng trước khi áp dụng K-Means. Do thuật toán dựa trên khoảng cách Euclidean, các đặc trưng có thang đo lớn (như thu nhập) dễ chi phối kết quả, vì vậy cần chuẩn hóa để đảm bảo tính cân bằng và hội tụ nhanh hơn.

– Phương án xử lý

- StandardScaler (Z-score) – phù hợp dữ liệu chuẩn nhưng nhạy cảm với outliers.
- RobustScaler (Median/IQR) – ít bị ảnh hưởng bởi outliers, thích hợp cho dữ liệu kinh tế lệch phải.
- Ba chiến lược scaling:
 - Demographic: Chuẩn hóa Age, Income, Dependency_Ratio; giữ nguyên Education_ord và Life_Stage để phân tích hậu kiểm (vì không tham gia vào phân cụm).
 - Product-Channel: Chuẩn hóa các chỉ số hành vi mua sắm (Web_Engagement, Product_HHI, Store_Preference, PCA features); giữ nguyên đặc trưng mô tả sản phẩm.
 - RFM: Chuẩn hóa Recency, Frequency, Monetary và các biến PCA liên quan.

– Ưu điểm cách tiếp cận:

- So sánh hiệu quả clustering giữa hai phương pháp.
- Linh hoạt xử lý outliers và tránh thiên lệch do chọn một phương pháp duy nhất.
- Tăng độ tin cậy và khả năng diễn giải kết quả.
 - ⇒ Hai phiên bản dữ liệu được tạo để so sánh hiệu quả trong bước phân cụm tiếp theo. Kỳ vọng RobustScaler sẽ cho kết quả tốt hơn, nhưng cả hai sẽ được đánh giá thực nghiệm để chọn phương pháp tối ưu.

a) Demographic Feature Scaling

Dữ liệu Demographic có 3 đặc trưng chính: Age, Income, Dependency_Ratio. Những đặc trưng này có thang đo khác nhau, do đó cần scaling để K-Means hoạt động hiệu quả.

Bảng 2.11 Demographic trước Scaling

Feature	Mean	Std	Min	Max	Skewness	Status
Age	45.15	11.73	18	100	0.137	Gần chuẩn
Income	52,048	21,619	1,730	162,397	0.367	Lệch phải
Dependency_Ratio	0.400	0.306	0.0	1.063	0.089	Gần chuẩn

Nhận xét: Income có phạm vi lớn ($Q3=68,592$ vs $Min=1,730$), có thể gây ảnh hưởng nếu dùng StandardScaler.


– Kết quả scaling

- StandardScaler
 - Age: $Mean \approx 0$, $Std = 1$


CHƯƠNG 2. CHUẨN BỊ DỮ LIỆU

- Income: Mean ≈ 0 , Std = 1
- Dependency_Ratio: Mean ≈ 0 , Std = 1


Outliers ($|z| > 3$): Income có 49 outliers (2.44%) $\rightarrow$ vấn đề đáng chú ý.



Hình 2.18 Kết quả scaling Age bằng StandardScaler




Hình 2.19 Kết quả scaling Dependency_Ratio bằng StandardScaler




Hình 2.20 Kết quả scaling Income bằng StandardScaler

- RobustScaler
 - Age: Median ≈ 0 , IQR = 1
 - Income: Median ≈ 0 , IQR = 1
 - Dependency_Ratio: Median ≈ 0 , IQR = 1


Outliers ($|z| > 3$): Income chỉ còn 3 outliers (0.15%) $\rightarrow$ tốt hơn rõ rệt.



Hình 2.21 Kết quả scaling Age bằng RobustScaler



Hình 2.22 Kết quả scaling Dependency_Ratio bằng RobustScaler



Hình 2.23 Kết quả scaling Income bằng RobustScaler

Bảng 2.12: So sánh 2 phương pháp scale với Demographic

Tiêu chí	StandardScaler	RobustScaler
Income Outliers	49 (2.44%) – khá nhiều	3 (0.15%) – rất ít
Extreme Values	$\max = 5.11\sigma$ (rất xa trung bình)	$\max = 3.35\sigma$ (ít cực đoan hơn)
Distribution Shape	Dữ liệu bị ép về Gaussian-like	Giữ nguyên phân phối gốc tốt hơn
Sensitivity to Outliers	Cao – dễ bị ảnh hưởng bởi giá trị cực đoan	Thấp – ổn định hơn với outliers

– Ý nghĩa

- Income Outliers: Cho thấy StandardScaler tạo ra nhiều điểm dữ liệu có giá trị chuẩn hóa vượt quá ± 3 (outliers), trong khi RobustScaler giảm đáng kể số lượng này.

- Extreme Values: StandardScaler làm cho một số giá trị trở nên cực đoan hơn (5.11σ), còn RobustScaler giữ chúng gần hơn với trung tâm (3.35σ).

- Distribution Shape: StandardScaler ép dữ liệu về dạng gần Gaussian, trong khi RobustScaler bảo toàn hình dạng gốc, điều này quan trọng nếu dữ liệu lệch tự nhiên.

- Sensitivity to Outliers: StandardScaler nhạy cảm với outliers, dễ bị ảnh hưởng; RobustScaler ít bị ảnh hưởng, phù hợp cho dữ liệu kinh tế vốn có outliers hợp lệ.

– Kết luận: RobustScaler là lựa chọn tốt hơn cho dữ liệu Demographic vì nó xử lý outliers hiệu quả hơn và bảo toàn đặc tính tự nhiên của dữ liệu.

– Dataset: Robust Scaling: [Customer_Behavior_Demographic_Robust_scaled.xlsx](#)

b) Product + Channel Feature Scaling

Dữ liệu ProductChannel có 4 đặc trưng chính: Product_HHI, Store_Preference, Web_Engagement, PC1_Total_TotalPurchases. Những đặc trưng này đo lường hành vi mua sắm và sở thích kênh bán hàng với các thang đo rất khác nhau (Product_HHI: 0.17-0.99, Web_Engagement: 0-20). Cần scaling để K-Means hoạt động hiệu quả.

- Trước khi scaling

Bảng 2.13 Product + Channel trước Scaling

Feature	Mean	Std	Min	Max	Skewness	Issue
Product_HHI	0.391	0.156	0.167	0.994	1.053	Lệch phải rõ
Store_Preference	0.408	0.121	0.0	1.0	0.059	Gần chuẩn
Web_Engagement	5.314	2.437	0	20	0.279	Phạm vi rộng
PC1_Total_TotalPurchases	0.000	1.369	-2.856	3.659	-0.081	Đã chuẩn hóa


- Nhận xét
 - Product_HHI có skewness cao (1.053) → phân phối lệch phải rõ rệt.
 - Web_Engagement có phạm vi rất rộng (0–20), gấp ~20 lần so với mean → StandardScaler dễ bị ảnh hưởng.

- Kết quả scaling


- StandardScaler
 - Validation:
 - Product_HHI: Mean ≈ 0 , Std = 1
 - Store_Preference: Mean ≈ 0 , Std = 1
 - Web_Engagement: Mean ≈ 0 , Std = 1
 - PC1_Total_TotalPurchases: Mean ≈ 0 , Std = 1
 - Extreme Values ($|z| > 3$):

CHƯƠNG 2. CHUẨN BỊ DỮ LIỆU

- Product_HHI: max = 3.87σ → chứa giá trị cực đoan
- Store_Preference: 7 outliers
- Web_Engagement: 15 outliers ($\approx 0.75\%$)
- PC1_Total_TotalPurchases: Không có outliers




Hình 2.24 Kết quả scaling PC1_Total_TotalPurchases bằng StandardScaler




Hình 2.25 Kết quả scaling Product_HHI bằng StandardScaler

CHƯƠNG 2. CHUẨN BỊ DỮ LIỆU



Hình 2.26 Kết quả scaling Store_Preference bằng StandardScaler




Hình 2.27 Kết quả scaling Web_Engagement bằng StandardScaler


- RobustScaler
 - Validation:
 - Product_HHI: Median ≈ 0 , IQR = 1
 - Store_Preference: Median ≈ 0 , IQR = 1
 - Web_Engagement: Median ≈ 0 , IQR = 1
 - PC1_Total_TotalPurchases: Median ≈ 0 , IQR = 1
 - Extreme Values ($|z| > 3$):
 - Product_HHI: 1 outlier (0.05%)
 - Store_Preference: Không đáng kể
 - Web_Engagement: 3 outliers (0.15%)
 - PC1_Total_TotalPurchases: Không có outliers

Cải thiện: RobustScaler giảm outliers đáng kể và bảo toàn phân phối gốc.


CHƯƠNG 2. CHUẨN BỊ DỮ LIỆU




Hình 2.28 Kết quả scaling PC1_Total_TotalPurchases bằng RobustScaler



Hình 2.29 Kết quả scaling Product_HHI bằng RobustScaler



Hình 2.30 Kết quả scaling Store_Preference bằng RobustScaler



Hình 2.31 Kết quả scaling Web_Engagement bằng RobustScaler

Bảng 2.14 So sánh 2 phương pháp scaling với ProductChannel

Tiêu chí	StandardScaler	RobustScaler
Product_HHI Max	3.87 σ	3.20 σ
Web_Engagement Outliers	15 (0.75%)	3 (0.15%)
Skewness Preservation	Removed	Preserved
Reference Features	Preserved	Preserved
Extreme Value Handling	Kém	Tốt

– Ý nghĩa

- Product_HHI Max: Giá trị chuẩn hóa lớn nhất của biến Product_HHI. StandardScaler tạo ra giá trị cực đoan hơn (3.87σ), trong khi RobustScaler giữ gần trung tâm hơn (3.20σ) → RobustScaler tốt hơn.
- Web_Engagement Outliers: Số lượng điểm vượt ngưỡng $|z| > 3$. StandardScaler có 15 outliers (0.75%), RobustScaler chỉ còn 3 (0.15%) → RobustScaler giảm đáng kể outliers.
- Skewness Preservation: StandardScaler ép dữ liệu về dạng gần Gaussian (mất tính lệch), còn RobustScaler giữ nguyên phân phối lệch phải (quan trọng cho dữ liệu hành vi thực tế).
- Reference Features: Cả hai phương pháp đều giữ nguyên các biến tham chiếu (không scale) → hòa.
- Extreme Value Handling: StandardScaler xử lý kém, RobustScaler xử lý tốt hơn

– Kết luận

Qua phân tích, RobustScaler cho thấy hiệu quả vượt trội so với StandardScaler trong việc xử lý dữ liệu Product-Channel. Nó giảm số lượng outliers đáng kể, bảo tồn phân phối lệch tự nhiên của Product_HHI và xử lý tốt các giá trị cực đoan. Do đó, RobustScaler được khuyến nghị sử dụng cho bước K-Means tiếp theo, trong khi StandardScaler vẫn được lưu giữ để đối chiếu khi cần.

– Dataset: Robust scaling: [Customer_Behavior_ProductChannel_Robust_scaled.xlsx](#)

c) RFM Feature Scaling

- Dữ liệu RFM có 4 đặc trưng chính:

Recency, Income_per_Family_Member_Transformed, PC1_TotalPurchases_Total, PC1_AvgPerPurchase_Income. Những đặc trưng này đo lường hành vi mua sắm khách hàng với các thang đo khác nhau. Cần scaling để K-Means hoạt động hiệu quả cho phân cụm giá trị khách hàng.

- Trước khi scaling:

Bảng 2.15 Trước scaling RFM

Feature	Mean	Std	Min	Max	Skewness	Status
Recency	49.06	28.95	0	99	-0.004	Đối xứng
Income_per_Family	31.29	4.57	14.47	44.91	-0.006	Đối xứng
PC1_TotalPurchases	0.00	1.33	-2.08	3.99	0.308	Lệch phải nhẹ
PC1_AvgPerPurchase	0.00	1.34	-3.78	4.86	0.079	Gần đối xứng

- Nhận xét:
 - Recency & Income_per_Family: Dữ liệu gốc (raw features).
 - PC1 components: Đã transform từ giai đoạn Feature Engineering, sẵn chuẩn hóa.
 - PC1_TotalPurchases có skewness 0.308 → lệch phải nhẹ.

– Kết quả Scaling

▪ StandardScaler


● Validation:

- Recency: Mean ≈ 0 , Std = 1
- Income_per_Family: Mean ≈ 0 , Std = 1
- PC1_TotalPurchases: Mean ≈ 0 , Std = 1
- PC1_AvgPerPurchase: Mean ≈ 0 , Std = 1


● Extreme Values ($|z| > 3$):

- Recency: Không có outliers
- Income_per_Family: 1 outlier (min)
- PC1_TotalPurchases: 1 outlier (max)
- PC1_AvgPerPurchase: 2 outliers


Tổng cộng: 4 outliers đơn lẻ, mức ảnh hưởng thấp nhưng vẫn tồn tại.




Hình 2.32 Kết quả scaling Income_per_Family_Member_Transformed bằng StandardScaler



Hình 2.33 Kết quả scaling PC1_AvgPerPurchases_Income bằng StandardScaler




Hình 2.34 Kết quả scaling PC1_TotalPurchases_Total bằng StandardScaler




Hình 2.35 Kết quả scaling Recency bằng StandardScaler

- RobustScaler
 - Validation:
 - Recency: Median ≈ 0 , IQR = 1
 - Income_per_Family: Median ≈ 0 , IQR ≈ 1
 - PC1_TotalPurchases: Median ≈ 0 , IQR ≈ 1
 - PC1_AvgPerPurchase: Median ≈ 0 , IQR = 1
 - Extreme Values ($|z| > 3$):
 - Không có outliers ở tất cả các biến
 - Tổng cộng: 0 outliers $\rightarrow$ RobustScaler xử lý sạch hơn.




Hình 2.36 Kết quả scaling Income_per_Family_Member_Transformed bằng RobustScaler




Hình 2.37 Kết quả scaling PC1_AvgPerPurchases_Income bằng RobustScaler

CHƯƠNG 2. CHUẨN BỊ DỮ LIỆU



Hình 2.38 Kết quả scaling PC1_TotalPurchases_Total bằng RobustScaler



Hình 2.39 Kết quả scaling Recency bằng RobustScaler

- So sánh giữa 2 phương pháp

Bảng 2.16 So sánh 2 phương pháp scaling cho RFM

Tiêu chí	StandardScaler	RobustScaler
Total Outliers	z	> 3
Recency Range	[-1.70, 1.73]	[-0.98, 1.00]
Income_Family Range	[-3.68, 2.98]	[-2.63, 2.22]
PC1_TotalPurchases Range	[-1.57, 3.01]	[-0.80, 1.68]
PC1_AvgPerPurchase Range	[-2.82, 3.63]	[-1.61, 2.11]
Mean Validation	All ≈ 0	All ≈ 0
Std/IQR Validation	All = 1	All = 1

– Ý nghĩa

- Total Outliers: RobustScaler loại bỏ hoàn toàn outliers (0), trong khi StandardScaler vẫn còn 4 giá trị vượt ngưỡng.
- Range của các biến: RobustScaler thu hẹp phạm vi dữ liệu về gần trung tâm hơn (ví dụ Recency từ $[-1.70, 1.73]$ xuống $[-0.98, 1.00]$), giúp giảm ảnh hưởng của giá trị cực đoan.
- Mean & Std/IQR Validation: Cả hai phương pháp đều đạt chuẩn hóa ($\text{Mean} \approx 0$, Std hoặc IQR = 1), nhưng RobustScaler xử lý outliers tốt hơn.

– Kết luận

Sau khi so sánh hai phương pháp chuẩn hóa, RobustScaler cho thấy hiệu quả vượt trội trong việc xử lý dữ liệu RFM. Không xuất hiện outliers sau chuẩn hóa, trong khi StandardScaler vẫn còn 4 giá trị cực đoan. RobustScaler cũng thu hẹp phạm vi dữ liệu về gần trung tâm hơn, giúp giảm ảnh hưởng của giá trị lệch. Do đó, RobustScaler được khuyến nghị sử dụng cho bước K-Means tiếp theo, trong khi StandardScaler vẫn được lưu giữ để đối chiếu khi cần.

– Dataset:

Robust scaling: [Customer_Behavior_RFMRobust_scaled.xlsx](#)

CHƯƠNG 3. XÂY DỰNG MÔ HÌNH

3.1. Giới thiệu mô hình

3.1.1. Khái niệm

K-Means là một thuật toán phân cụm không giám sát (unsupervised learning) được sử dụng để chia dữ liệu thành K nhóm (clusters) dựa trên sự tương đồng giữa các điểm dữ liệu.

Mục tiêu: Tối thiểu hóa tổng bình phương khoảng cách giữa các điểm dữ liệu và tâm cụm (centroid).

3.1.2. Nguyên lý hoạt động

Thuật toán dựa trên khoảng cách Euclidean để đo độ tương đồng.

Quy trình cơ bản:

- Khởi tạo: Chọn ngẫu nhiên K tâm cụm ban đầu.
- Gán cụm: Mỗi điểm dữ liệu được gán vào cụm có tâm gần nhất.
- Cập nhật tâm cụm: Tính trung bình các điểm cụm để cập nhật tâm cụm.
- Lặp lại: Tiếp tục gán và cập nhật cho đến khi hội tụ (tâm cụm không thay đổi hoặc đạt số vòng lặp tối đa).

3.1.3. Ưu điểm

- Đơn giản, dễ triển khai.
- Hiệu quả với dữ liệu lớn.
- Tốc độ hội tụ nhanh.

3.1.4. Hạn chế

- Phải xác định trước số cụm K.
- Nhạy cảm với giá trị khởi tạo.
- Không phù hợp cho cụm có hình dạng phức tạp hoặc phân phối phi tuyến.
- Dễ bị ảnh hưởng bởi outliers.

3.2. Ví dụ minh họa

Ta sẽ lấy ví dụ minh họa cụ thể với 1 trong 3 dataset đã qua Tiền xử lý và Xây dựng đặc trưng là Demographic - Phân cụm dựa trên thông tin cá nhân cơ bản của khách hàng.

3.2.1. Ý tưởng triển khai

K ngẫu nhiên từ 1 đến 10: Giả sử chưa biết số cụm tối ưu.

Vòng lặp K-Means:

- Khởi tạo tâm cụm.
- Gán mỗi điểm vào cụm gần nhất (dựa trên khoảng cách Euclidean).
- Cập nhật tâm cụm bằng trung bình các điểm trong cụm.
- Lặp lại cho đến khi hội tụ

3.2.2. Công thức cốt lõi

Công thức khoảng cách Euclidean cơ bản

$$d(P, Q) = \sqrt{\{(x_1 - y_1)^2 + (x_2 - y_2)^2 + \dots + (x_n - y_n)^2\}}$$

Trong đó:

- $P = (x_1, x_2, \dots, x_n)$: tọa độ của điểm thứ nhất trong không gian n chiều.
- $Q = (y_1, y_2, \dots, y_n)$: tọa độ của điểm thứ hai trong cùng không gian.

Hàm mục tiêu (SSE)

$$J = \sum_{i=1}^K \sum_{x \in C_i} |x - \mu_i|^2$$

Trong đó:

- K : số cụm.
- C_i : tập các điểm thuộc cụm i.
- μ_i : tâm cụm i.
- $|x - \mu_i|^2$: bình phương khoảng cách Euclidean từ điểm x đến centroid μ_i .

=> Công thức này là trái tim của K-Means, nó định nghĩa cái mà thuật toán đang cố gắng tối ưu: giảm tổng khoảng cách bình phương từ điểm đến tâm cụm.

3.2.3. Quy trình xây dựng mô hình

a) Khởi tạo tâm cụm

- Khởi tạo ngẫu nhiên
 - Cách làm: chọn ngẫu nhiên K điểm dữ liệu trong tập để làm centroid ban đầu.
 - Ưu điểm: đơn giản, nhanh.
 - Nhược điểm: dễ dẫn đến kết quả không ổn định (cụm chòng lún, hội tụ chậm), vì chọn điểm khởi tạo không có chiến lược.
- Khởi tạo bằng KMeans++
 - Cách làm: chọn centroid đầu tiên ngẫu nhiên, sau đó các centroid tiếp theo được chọn dựa trên xác suất tỷ lệ với khoảng cách bình phương đến centroid gần nhất.
 - Ý nghĩa: đảm bảo các centroid ban đầu cách xa nhau, giảm
 - Ưu điểm: thường cho kết quả tốt hơn, hội tụ nhanh hơn, ổn định hơn.
 - Nhược điểm: phức tạp hơn một chút so với random, nhưng vẫn rất hiệu quả.

b) Gán cụm

- Tính khoảng cách Euclidean từ mỗi điểm đến các tâm cụm.
- Gán điểm vào cụm có tâm gần nhất.
- Chức năng: phân loại tạm thời dữ liệu theo tâm cụm hiện tại.

c) Cập nhật tâm cụm

- Tính trung bình các điểm trong từng cụm để tạo tâm cụm mới.
- Nếu cụm rỗng, chọn ngẫu nhiên một điểm để thay thế.
- Chức năng: dịch chuyển tâm cụm để phản ánh vị trí trung tâm mới của dữ liệu.

d) Lập lại

- Thực hiện bước 2 và 3 liên tục cho đến khi tâm cụm không thay đổi (hội tụ) hoặc đạt số vòng lặp tối đa.
- Chức năng: đảm bảo thuật toán tìm được cấu trúc cụm ổn định.
- Để cụ thể, ta sẽ thử làm vài phép tính minh họa với 6 điểm dữ liệu từ Demographic dataset cùng 2 đặc trưng đầu tiên (Age, Income), với $K = 3$:

$$\begin{aligned} x_1 &= (0.72, 0.19) & x_4 &= (-0.77, -0.75) \\ x_2 &= (0.88, -0.15) & x_5 &= (-0.61, 0.20) \\ x_3 &= (0.27, 0.60) & x_6 &= (0.16, 0.33) \end{aligned}$$

- Khởi tạo tâm cụm ban đầu

$$c_1^{(0)} = x_1 = (0.72, 0.19), c_2^{(0)} = x_5 = (-0.61, 0.20), c_3^{(0)} = x_6 = (0.16, 0.33)$$

Công thức khoảng cách Euclid

$$d(x, c) = \sqrt{(x_1 - c_1)^2 + (x_2 - c_2)^2}$$

- Vòng lặp 1:

Điểm x_1 :

$$\begin{aligned} \circ \quad d(x_1, c_1^{(0)}) &= \sqrt{(0.72 - 0.72)^2 + (0.19 - 0.19)^2} = 0 \\ \circ \quad d(x_1, c_2^{(0)}) &= \sqrt{(0.72 + 0.61)^2 + (0.19 - 0.2)^2} \approx 1.33 \\ \circ \quad d(x_1, c_3^{(0)}) &= \sqrt{(0.72 - 0.16)^2 + (0.19 - 0.33)^2} \approx 0.577 \end{aligned}$$

→ Gán vào cụm 1.

Điểm x_2 :

$$\begin{aligned} \circ \quad d(x_2, c_1^{(0)}) &= \sqrt{(0.88 - 0.72)^2 + (-0.15 - 0.19)^2} \approx 0.376 \\ \circ \quad d(x_2, c_2^{(0)}) &\approx 1.503 \\ \circ \quad d(x_2, c_3^{(0)}) &\approx 0.861 \end{aligned}$$

→ Gán vào cụm 1.

Kết quả gán:

$$\text{Cụm 1 : } \{x_1, x_2\}, \text{ Cụm 2 : } \{x_4, x_5\}, \text{ Cụm 3 : } \{x_3, x_6\}$$

- Cập nhật tâm cụm

$$\begin{aligned} \circ \quad c_1^{(1)} &= \frac{1}{2} \sum_{i \in C_1} x_i = \left(\frac{0.72 + 0.88}{2}, \frac{0.19 - 0.15}{2} \right) = (0.80, 0.02) \\ \circ \quad c_2^{(1)} &= (-0.69, -0.275) \\ \circ \quad c_3^{(1)} &= (0.215, 0.465) \end{aligned}$$

- Vòng lặp 2:

$$\circ \quad x_1 \rightarrow c_1^{(0)} \approx 0.188; c_2^{(1)} \approx 1.485; c_3^{(3)} \approx 0.575 \rightarrow \text{giữ cụm 1}$$

- $x_2 \rightarrow c_1^{(0)} \approx 0.188; c_2^{(1)} \approx 1.576; c_3^{(3)} \approx 0.905 \rightarrow$ giữ cụm 1
- $x_3 \rightarrow c_1^{(0)} \approx 0.786; c_2^{(1)} \approx 1.298; c_3^{(3)} \approx 0.146 \rightarrow$ giữ cụm 3
- $x_4 \rightarrow c_1^{(0)} \approx 1.748; c_2^{(1)} \approx 0.482; c_3^{(3)} \approx 1.564 \rightarrow$ giữ cụm 2
- $x_5 \rightarrow c_1^{(0)} \approx 1.422; c_2^{(1)} \approx 0.482; c_3^{(3)} \approx 0.867 \rightarrow$ giữ cụm 2
- $x_6 \rightarrow c_1^{(0)} \approx 0.711; c_2^{(1)} \approx 1.043; c_3^{(3)} \approx 0.146 \rightarrow$ giữ cụm 3

$\Rightarrow$ **Cụm không thay đổi, chứng tỏ mô hình đã đến ngưỡng hội tụ**

– Tính SSE (WCSS) sau khi mô hình hội tụ:

- Cụm 1 ($c_1^{(0)} = (0.80, 0.02)$):
 - $x_1 = (0.72, 0.19): x_1 \rightarrow c_1^{(0)} = 0.0353$
 - $x_2 = (0.88, -0.15): x_2 \rightarrow c_1^{(0)} = 0.0353$
 - Tổng C1 = 0.0706
- Cụm 2 ($c_2^{(2)} = (-0.69, -0.275)$):
 - $x_4 = (-0.77, -0.75): x_4 \rightarrow c_2^{(2)} = 0.2320$
 - $x_5 = (-0.61, 0.20): x_5 \rightarrow c_2^{(2)} = 0.2320$
 - Tổng C2 = 0.46405
- Cụm 3 ($c_3^{(3)} = (0.215, 0.465)$):
 - $x_3 = (0.27, 0.60): x_3 \rightarrow c_3^{(3)} = 0.0212$
 - $x_6 = (0.16, 0.33): x_6 \rightarrow c_3^{(3)} = 0.0212$
 - Tổng C3 = 0.0425

$\Rightarrow$ **Tổng SSE $\approx 0.0706 + 0.46405 + 0.0425 = 0.57715$**

$\Rightarrow$ **Phản ánh chất lượng chặt trong một cụm.**

3.3. Cài đặt thuật toán

3.3.1. Khởi tạo tâm cụm

- Khởi tạo ngẫu nhiên

```
def _init_centroids_random(self, X):  
    """Initialize centroids randomly."""  
    np.random.seed(self.random_state)  
    random_indices = np.random.choice(X.shape[0], self.n_clusters, replace=False)  
    return X[random_indices].copy()
```

- Khởi tạo bằng KMeans++

```
def _init_centroids_kmeans_plus_plus(self, X):  
    """Initialize centroids using K-Means++ algorithm."""  
    np.random.seed(self.random_state)  
    n_samples = X.shape[0]  
  
    # Bước 1: Chọn centroid đầu tiên ngẫu nhiên  
    centroids = [X[np.random.randint(n_samples)]]  
  
    # Bước 2-K: Chọn các centroid tiếp theo dựa trên khoảng cách xác suất  
    for _ in range(1, self.n_clusters):  
        # Tính khoảng cách từ mỗi điểm tới centroid gần nhất hiện tại  
        distances = np.array([  
            min([np.linalg.norm(x - c)**2 for c in centroids])  
            for x in X  
        ])  
  
        # Chuyển đổi khoảng cách thành xác suất (d2-weighting)  
        probabilities = distances / distances.sum()  
        cumulative_probs = probabilities.cumsum()
```

```
r = np.random.rand()

# Chọn điểm tiếp theo dựa trên xác suất tích lũy
for idx, cum_prob in enumerate(cumulative_probs):
    if r < cum_prob:
        centroids.append(X[idx])
        break

return np.array(centroids)
```

3.3.2. Gán cụm

```
def _assign_clusters(self, X, centroids):
    """Assign each sample to nearest centroid."""
    distances = np.zeros((X.shape[0], self.n_clusters))

    # Tính khoảng cách Euclidean từ mỗi điểm tới mỗi centroid
    for k in range(self.n_clusters):
        distances[:, k] = np.linalg.norm(X - centroids[k], axis=1)

    # Gán mỗi điểm vào cụm có centroid gần nhất
    return np.argmin(distances, axis=1)
```

3.3.3. Cập nhật tâm cụm

```
def _update_centroids(self, X, labels):
    """Update centroids as mean of assigned samples."""
    centroids = np.zeros((self.n_clusters, X.shape[1]))

    # Với mỗi cụm, tính trung bình các điểm thuộc cụm đó
    for k in range(self.n_clusters):
        cluster_points = X[labels == k]
```

```
if len(cluster_points) > 0:
    # Centroid mới = trung bình các điểm trong cụm
    centroids[k] = cluster_points.mean(axis=0)
else:
    # Nếu cụm rỗng, chọn điểm ngẫu nhiên (tránh centroid mờ cô)
    centroids[k] = X[np.random.randint(X.shape[0])]

return centroids
```

3.3.4. Lặp lại

```
def fit(self, X):
    """Fit K-Means clustering."""
    X = np.array(X)
    best_inertia = np.inf
    best_centroids = None
    best_labels = None
    best_n_iter = 0

    # Chạy K-Means n_init lần với khởi tạo khác nhau
    for init_run in range(self.n_init):
        # Bước 1: Khởi tạo centroids
        if self.init_method == 'kmeans++':
            centroids = self._init_centroids_kmeans_plus_plus(X)
        else:
            centroids = self._init_centroids_random(X)

        # Bước 2: Lặp lại (Assignment + Update) cho đến khi hội tụ
        for iteration in range(self.max_iter):
```

```
# 2a. Gán cụm
labels = self._assign_clusters(X, centroids)

# 2b. Cập nhật centroids
new_centroids = self._update_centroids(X, labels)

# 2c. Kiểm tra sự hội tụ
centroid_shift = np.linalg.norm(new_centroids - centroids)
centroids = new_centroids

# Nếu centroids di chuyển rất ít → Hội tụ
if centroid_shift < self.tol:
    break

# Bước 3: Tính inertia và chọn kết quả tốt nhất
inertia = self._calculate_inertia(X, labels, centroids)

if inertia < best_inertia:
    best_inertia = inertia
    best_centroids = centroids
    best_labels = labels
    best_n_iter = iteration + 1
# Lưu kết quả tốt nhất
self.cluster_centers_ = best_centroids
self.labels_ = best_labels
self.inertia_ = best_inertia
self.n_iter_ = best_n_iter
return self
```

3.4. Thước đo đánh giá mô hình

3.4.1. Tiêu chí đánh giá nội

Khái niệm: Dựa trên đặc tính nội tại của dữ liệu và kết quả phân cụm, không cần thông tin nhãn gốc.

a) Elbow Method

- Tiêu chí: Tìm điểm "gấp khúc" trên đồ thị WCSS và K
- WCSS: Tổng bình phương khoảng cách từ mỗi điểm tới centroid của cụm nó thuộc về
- Nguyên tắc: K tối ưu là điểm mà WCSS giảm chậm lại.
- Cách tìm: Tính khoảng cách vuông góc từ mỗi điểm K tới đường nối K_{min} và K_{max} , chọn K có khoảng cách lớn nhất.
- Giới hạn: Không luôn tìm được "khuyết tay" rõ ràng, đặc biệt khi WCSS giảm tuyến tính.

b) Silhouette Score


- Tiêu chí: Đo độ tách biệt giữa các cụm và độ chặt của dữ liệu nội cụm
 - Giá trị: $[-1, 1]$
 - > 0.5 : Cụm tách biệt tốt (Tốt)
 - $0.3-0.5$: Cụm ổn định (Chấp nhận được)
 - < 0.3 : Cụm bị chồng lấp (Yếu)
 - Nguyên tắc: K tối ưu là K cho Silhouette Score cao nhất
 - Ưu điểm: Phản ánh compactness (độ gắn kết), separation (tách biệt)
- Giới hạn: Có thể không nhạy với dữ liệu phức tạp
- **Quyết định cuối: Kết hợp 2 phương pháp**
 - Nếu Elbow K = Silhouette K $\rightarrow$ Chọn K đó
 - Nếu khác nhau $\rightarrow$ Chọn K được gợi ý bởi cả 2, ta có thể tùy chỉnh lại

CHƯƠNG 4. KẾT QUẢ THỰC NGHIỆM

4.1. Mô hình tự cài đặt

4.1.1. Demographic


Gợi ý số K tối ưu từ Elbow Method và Silhouette Score



Hình 4.1: Elbow method vs Silhouette score Demographic


Nhận xét: có thể thấy rằng Elbow Method đã gợi ý rằng số cụm K tối ưu là 4, tuy nhiên thì Silhouette Score lại chỉ ra số cụm K nên là 3

a) K = 3 (theo Silhouette Score gợi ý)




Hình 4.2: Kết quả phân cụm Demographic với K = 3

CHƯƠNG 4. KẾT QUẢ THỰC NGHIỆM




Hình 4.3: Phân phối trình độ học vấn Demographic theo K = 3



Hình 4.4: Phân phối Giai đoạn cuộc sống Demographic theo K = 3

CHƯƠNG 4. KẾT QUẢ THỰC NGHIỆM



Hình 4.5: Biểu đồ đường Demographic theo K = 3

– Cụm 0: "High-Income Singles/Couples" (517 khách hàng - 25.57%)

- Tuổi: 38.40 năm (trẻ)
- Thu nhập: 73,029 (cao nhất)
- Tỷ lệ phụ thuộc: 0.1559 (thấp nhất)

⇒ Đặc điểm: Thanh niên độc thân hoặc cặp vợ chồng không con, thu nhập cao, tự do tài chính

– Cụm 1: "Mature Empty Nesters" (670 khách hàng - 33.53%)

- Tuổi: 58.13 năm (cao nhất)
- Thu nhập: 58,855 (trung bình)
- Tỷ lệ phụ thuộc: 0.3322 (trung bình)

⇒ Đặc điểm: Người trưởng thành, giai đoạn "Empty Nest", con cái đã lớn, thu nhập vừa phải


– Cụm 2: "Young Families with Dependents" (823 khách hàng - 40.90%)

- Tuổi: 38.74 năm (trẻ)
- Thu nhập: 33,347 (thấp)
- Tỷ lệ phụ thuộc: 0.6091 (cao nhất)


CHƯƠNG 4. KẾT QUẢ THỰC NGHIỆM

⇒ Đặc điểm: Gia đình trẻ có nhiều con nhỏ, thu nhập thấp, chi phí phụ thuộc cao


b) $K = 4$ (theo Elbow Method gợi ý)




Hình 4.6: Kết quả phân cụm Demographic với $K = 4$



Hình 4.7: Phân phối trình độ học vấn Demographic theo $K = 4$



Hình 4.8: Phân phối Giai đoạn cuộc sống Demographic theo K =4



Hình 4.9: Biểu đồ đường Demographic theo K = 4

Phân tích sơ bộ ý nghĩa của kết quả phân cụm với $K = 4$ trên Demographic

– **Cụm 0: Premium Empty**

- Tuổi: 60+ (cao)
- Thu nhập: rất cao
- Tỷ lệ phụ thuộc: thấp

Đặc điểm: Nhóm khách hàng lớn tuổi, con cái đã trưởng thành, thu nhập cao, thường tiêu dùng sản phẩm/dịch vụ cao cấp.

– **Cụm 1: Budget Senior**

- Tuổi: 55+ (cao)
- Thu nhập: thấp
- Tỷ lệ phụ thuộc: cao

Đặc điểm: Nhóm khách hàng cao tuổi, thu nhập hạn chế, vẫn còn gánh nặng gia đình, nhạy cảm với giá cả.

– **Cụm 2: Struggling Young Families**

- Tuổi: 35-45 (trẻ)
- Thu nhập: thấp
- Tỷ lệ phụ thuộc: rất cao

Đặc điểm: Nhóm gia đình trẻ có nhiều con nhỏ, thu nhập thấp, chi phí sinh hoạt và phụ thuộc cao.

– **Cụm 3: Affluent Young Professionals**

- Tuổi: 25-40 (trẻ)
- Thu nhập: rất cao
- Tỷ lệ phụ thuộc: thấp

Đặc điểm: Nhóm chuyên gia trẻ, học vấn cao, thu nhập vượt trội, ít gánh nặng gia đình, sẵn sàng chi tiêu cho sản phẩm/dịch vụ cao cấp.

– Tổng kết

Qua quá trình thực nghiệm với phương pháp Elbow Method và Silhouette Score, mô hình K-Means với $K=3$ được xác định là giải pháp tối ưu cho phân cụm khách hàng theo nhân khẩu học.

Kết quả Silhouette Score cho $K=3$ (0.3506) cao hơn $K=4$ (0.3193) khoảng 3.1%, cho thấy sự phân tách rõ ràng và bao gồm tốt hơn. Elbow Method cũng xác nhận $K=3$ là điểm khuỷu tay với WCSS giảm 28.32%, trong khi $K=4$ chỉ cải thiện thêm 18.79% với lợi ích giảm dần. Ba cụm $K=3$ phân chia khách hàng thành ba nhóm có ý nghĩa kinh doanh rõ ràng:

- Affluent Young Professionals (chuyên gia trẻ thu nhập cao, tự do tài chính)
- Struggling Young Families (gia đình trẻ áp lực cao)
- Premium/Budget Seniors (người trưởng thành/hưu trí).


Phân chia này không chỉ dễ hiểu mà còn dễ chuyển thành chiến lược marketing cụ thể.

Mặc dù $K=4$ cung cấp chi tiết hơn bằng cách tách Premium Empty Nesters khỏi Budget Seniors, nó đi kèm với chi phí quản lý: (1) tỷ lệ phân loại sai có nguy cơ tăng cao hơn, (2) cần 4 chiến lược marketing thay vì 3, vô tình làm phức tạp phân bổ ngân sách, và (3) các cụm nhỏ hơn có thể không đạt để triển khai campaign hiệu quả.

Vì vậy, $K=3$ là lựa chọn tối ưu, cân bằng hoàn hảo giữa độ chính xác phân cụm, ý nghĩa kinh doanh, và khả năng triển khai chiến lược thực tế.

4.1.2. Product Channel


Gợi ý số K tối ưu từ Elbow Method và Silhouette Score



Hình 4.10: Elbow method vs Silhouette score Product Channel


Nhận xét: có thể thấy rằng cả 2 phương pháp Elbow Method lẫn Silhouette Score đều đồng thuận rằng $K = 4$ là lựa chọn tốt nhất

a) Với $K = 4$ (được cả Elbow Method và Silhouette Score công nhận)




Hình 4.11: Kết quả phân cụm Product Channel với $K = 4$

CHƯƠNG 4. KẾT QUẢ THỰC NGHIỆM




Hình 4.12: Độ quan tâm của khách hàng với từng sản phẩm cụ thể



Hình 4.13: Độ đa dạng khi mua hàng giữa các cụm

CHƯƠNG 4. KẾT QUẢ THỰC NGHIỆM



Hình 4.14: Biểu đồ đường ProductChannel cho K = 4

- Cụm 0: "Premium Product Seekers" (23.93% = 479 khách)
- Đặc điểm:
 - Product_HHI: -0.208 (thấp) → Mua rất đa dạng
 - Store_Preference: +0.62 (cao nhất) → Thích mua tại cửa hàng
 - Web_Engagement: +0.064 (vừa phải) → Tương tác web bình thường
 - PC1_Total_TotalPurchases: -0.71 (thấp) → Chi tiêu thấp
- Hành vi mua hàng:
 - Wine: 31.5% (thấp nhất)
 - Meat: 26.0% (cao)
 - Gold: 17.8% (cao nhất) → Quan tâm sản phẩm bổ sung
 - Fish: 10.5%, Fruit: 7.3%, Sweet: 6.9%
 - Dominant Product: Wine 46.8%, Meat 25.8%, Gold 15.8% Top Product Share: 0.425 (thấp) → Chọn sản phẩm đa dạng
- Ý nghĩa: Khách hàng cao cấp, thích mua ở cửa hàng, tìm Gold + sản phẩm bổ sung

CHƯƠNG 4. KẾT QUẢ THỰC NGHIỆM

- Cụm 1: "Balanced Buyers" (30.05% = 604 khách)
 - Đặc điểm:
 - Product_HHI: -0.047 (thấp) → Mua đa dạng các sản phẩm
 - Store_Preference: +0.11 (vừa phải) → Mua tại cửa hàng và web
 - Web_Engagement: -0.81 (thấp nhất) → Ít tương tác web
 - PC1_Total_TotalPurchases: +0.37 (cao) → Chi tiêu cao
 - Hành vi mua hàng:
 - Wine: 42.8% (trung bình)
 - Meat: 31.0% (cao)
 - Gold: 7.1%
 - Fish: 7.9%, Fruit: 5.6%, Sweet: 5.6%
 - Dominant Product: Wine 69.4%, Meat 29.6% Top Product Share: 0.475 (thấp) → Lựa chọn sản phẩm cân bằng
 - Ý nghĩa: Khách hàng cân bằng, ít dùng digital, mua cả Wine và Meat đều đặn
- Cụm 2: "Online Engagers" (25.42% = 518 khách)
 - Đặc điểm:
 - Product_HHI: -0.105 (thấp) → Mua đa dạng
 - Store_Preference: -0.70 (thấp nhất) → Ít mua tại cửa hàng
 - Web_Engagement: +0.23 (cao nhất) → Tương tác web nhiều
 - PC1_Total_TotalPurchases: -0.14 (thấp) → Chi tiêu thấp
 - Hành vi mua hàng:
 - Wine: 38.7% (trung bình)
 - Meat: 25.5% (cao)
 - Gold: 17.0% (cao)
 - Fish: 7.6%, Fruit: 5.2%, Sweet: 5.9%
 - Dominant Product: Wine 64.4%, Meat 17.6%, Gold 14.1% Top Product Share: 0.459 (thấp) → Lựa chọn cân bằng
 - Ý Nghĩa: Khách hàng kỹ thuật số, mua online, quan tâm Gold + các sản phẩm khác

CHƯƠNG 4. KẾT QUẢ THỰC NGHIỆM

– Cụm 3: "Wine Enthusiasts" (20.60% = 409 khách)

- Đặc điểm:
 - Product_HHI: +1.42 (cao nhất) → Mua chủ yếu 1 sản phẩm
 - Store_Preference: -0.13 (thấp) → Ít mua tại cửa hàng
 - Web_Engagement: -0.01 (trung bình) → Tương tác web vừa phải
 - PC1_Total_TotalPurchases: +0.07 (thấp) → Chi tiêu vừa phải
- Hành vi mua hàng:
 - Wine: 76.0% (cao nhất)
 - Meat: 14.3%
 - Gold: 5.9%
 - Cân bằng: 1.1% Fruit + 1.3% Fish + 1.3% Sweet
 - Dominant Product: Wine 98.1% (gần như toàn bộ) Top Product Share: 0.777 (cao nhất) → Tập trung mua 1 sản phẩm
- Ý nghĩa: Khách hàng chuyên mua rượu vang, không quan tâm đến sản phẩm khác

– Tổng kết


Kết quả phân cụm Product+Channel với $K = 4$ cho thấy sự đa dạng rõ rệt trong hành vi mua hàng của khách hàng.

- Premium Product Seekers: nhóm khách hàng cao cấp, thích mua trực tiếp tại cửa hàng, quan tâm đến các sản phẩm bổ sung như Gold.
- Balanced Buyers: nhóm mua hàng cân bằng, chi tiêu cao, ít sử dụng kênh digital, thường xuyên mua Wine và Meat.
- Online Engagers: nhóm khách hàng ưu tiên mua online, có mức tương tác web cao, quan tâm đến nhiều loại sản phẩm, đặc biệt là Gold.
- Wine Enthusiasts: nhóm chuyên mua rượu vang, ít quan tâm đến sản phẩm khác, hành vi tiêu dùng tập trung.

Phân cụm này giúp doanh nghiệp nhận diện rõ các phân khúc khách hàng khác nhau, từ đó xây dựng chiến lược marketing phù hợp: tập trung sản phẩm cao cấp cho nhóm Premium, chương trình khách hàng thân thiết cho Balanced Buyers, chiến dịch digital cho Online Engagers, và khuyến mãi chuyên biệt cho Wine Enthusiast

4.1.3. RSM


Gợi ý số K tối ưu từ Elbow Method và Silhouette Score



Hình 4.15: Elbow method vs Silhouette score RFM


Nhận xét: có thể thấy rằng Elbow Method đã gợi ý rằng số cụm K tối ưu là 5, tuy nhiên thì Silhouette Score lại chỉ ra số cụm K nên là 2

a) Với K = 2 (theo Silhouette Score gợi ý)



Hình 4.16: Kết quả phân cụm RFM với K = 2

CHƯƠNG 4. KẾT QUẢ THỰC NGHIỆM



Hình 4.17: Biểu đồ đường RFM với K =2

– Cụm 0: "At-Risk High-Value Customers" (949 khách)

- Đặc điểm
 - Recency: 49.25 ngày
 - Income_per_Family_Member_Transformed: 0.661
 - PC1_TotalPurchases_Total: 0.542
 - PC1_AvgPerPurchase_Income: 0.538
- Hành vi mua sắm
 - Hành vi: Đây là nhóm khách hàng từng mua rất nhiều, mỗi lần chi tiêu ở mức cao, có khả năng tài chính tốt. Tuy nhiên, gần 50 ngày qua họ không phát sinh giao dịch, cho thấy dấu hiệu giảm tương tác và nguy cơ rời bỏ.
 - Tâm lý: Họ từng trung thành và coi trọng thương hiệu, nhưng hiện tại có thể cảm thấy bị lãng quên, mệt mỏi vì quá nhiều lựa chọn, hoặc tò mò thử sản phẩm từ thương hiệu khác.
- Ý nghĩa kinh doanh: Đây là nhóm VIP quan trọng, nếu không được tái kích hoạt sẽ dễ mất vĩnh viễn. Doanh nghiệp cần chiến lược chăm sóc đặc biệt, khuyến mãi cá nhân hóa và tạo cảm giác được ưu tiên để giữ chân họ.


CHƯƠNG 4. KẾT QUẢ THỰC NGHIỆM

- Cụm 1: “Emerging Potential Customers” (1061 khách)
 - Đặc điểm
 - Recency: 48.90 ngày
 - Income_per_Family_Member_Transformed: -0.495
 - PC1_TotalPurchases_Total: -0.379
 - PC1_AvgPerPurchase_Income: -0.446
 - Hành vi mua sắm
 - Hành vi: Nhóm khách hàng mới hoặc chưa trung thành, thu nhập thấp, mỗi lần mua nhỏ nhưng vẫn còn hoạt động gần đây (Recency ~49 ngày). Họ đang trong giai đoạn khám phá sản phẩm và thương hiệu.
 - Tâm lý: Giá trị hiện tại thấp nhưng tiềm năng phát triển dài hạn. Họ cần được chăm sóc, hướng dẫn và tạo niềm tin để sẵn sàng chi tiêu nhiều hơn.
 - Ý nghĩa kinh doanh: Đây là nhóm khách hàng tiềm năng, nếu được nuôi dưỡng đúng cách có thể trở thành khách hàng trung thành. Chiến lược phù hợp là upsell/cross-sell, khuyến khích trải nghiệm thêm sản phẩm, và xây dựng quan hệ lâu dài.
- **Kết luận:**


Cụm 0 (At-Risk High-Value Customers) chiếm 47.06% với đặc điểm thu nhập cao, tần suất và giá trị mua hàng lớn nhưng hiện đang ngủ quên (Recency ~49 ngày), có nguy cơ mất khách VIP.

Ngược lại, cụm 1 (Emerging Potential Customers) chiếm 52.94%, thu nhập thấp, lịch sử mua ít và giá trị mỗi lần mua nhỏ, song vẫn active gần đây, thể hiện cơ hội phát triển nếu được chăm sóc và xây dựng quan hệ.

b) Với $K = 5$ (theo Elbow Method gợi ý)



Hình 4.18: Kết quả phân cụm RFM với $K = 5$



Hình 4.19: Biểu đồ đường RFM với $K = 5$

CHƯƠNG 4. KẾT QUẢ THỰC NGHIỆM

– Cụm 0: "VIPS - RECENT & HIGH-VALUE"

- Đặc điểm
 - Recency: 20-30 ngày
 - Income_per_Family_Member: +1.2 đến +1.5
 - PC1_TotalPurchases_Total: +0.8 đến +1.2
 - PC1_AvgPerPurchase_Income: +0.9 đến +1.3
- Hành vi mua sắm
 - Hành vi: Mua gần đây, thường xuyên, giá trị mỗi lần cao, thu nhập cao nhất.
 - Tâm lý: Trung thành, hài lòng, coi thương hiệu là lựa chọn số 1.
- Ý nghĩa kinh doanh: Nhóm VIP cần giữ chân, upsell sản phẩm/dịch vụ cao cấp, ROI cao nhất.

– Cụm 1: "PLATEAUING CUSTOMERS"

- Đặc điểm
 - Recency: 35-45 ngày (BÌNH THƯỜNG)
 - Income_per_Family_Member: +0.5 đến +0.8 (CAO)
 - PC1_TotalPurchases_Income: +0.3 đến +0.6 (TRUNG BÌNH THỨ 2)
 - PC1_AvgPerPurchase: +0.4 đến +0.7 (CAO)
- Hành vi mua sắm
 - Hành vi: Mua đều nhưng chu kỳ dài hơn, giá trị mỗi lần khá cao, thu nhập tốt.
 - Tâm lý: Khách hàng tốt nhưng có dấu hiệu giảm nhiệt, dễ thử thương hiệu khác.
- Ý nghĩa kinh doanh: Cần kích thích tăng tần suất, duy trì engagement để tránh mất khách.

CHƯƠNG 4. KẾT QUẢ THỰC NGHIỆM

– Cụm 2: "MAINSTREAM CUSTOMERS"

- Đặc điểm
 - Recency: 40-50 ngày
 - Income_per_Family_Member: -0.1 đến +0.3
 - PC1_TotalPurchases_Total: -0.2 đến +0.2
 - PC1_AvgPerPurchase_Income: -0.1 đến +0.2
- Hành vi mua sắm
 - Hành vi: Mua ở mức trung bình, không thường xuyên, giá trị mỗi lần vừa phải, thu nhập trung bình.
 - Tâm lý: Khách hàng phổ thông, không đặc biệt gắn bó, dễ bị lôi kéo bởi giá cả và khuyến mãi.
- Ý nghĩa kinh doanh: Có thể nâng cấp thành nhóm trung thành nếu tăng trải nghiệm và giá trị cảm nhận.

– Cụm 3: "NEW OR OCCASIONAL BUYERS"

- Đặc điểm
 - Recency: 45-50 ngày
 - Income_per_Family_Member: -0.5 đến -0.1
 - PC1_TotalPurchases_Total: -0.7 đến -0.3
 - PC1_AvgPerPurchase_Income: -0.7 đến -0.3
- Hành vi mua sắm
 - Hành vi: Vừa mua gần đây nhưng rất ít, giá trị mỗi lần thấp, thu nhập hạn chế.
 - Tâm lý: Khách mới hoặc mua thỉnh thoảng, nhạy cảm với giá, chưa tin tưởng thương hiệu.
- Ý nghĩa kinh doanh: Nhóm tiềm năng cần nuôi dưỡng, khuyến khích thử thêm sản phẩm, xây dựng niềm tin.

– Cụm 4: "AT-RISK DORMANT CUSTOMERS"

- Đặc điểm
 - Recency: 50+ ngày
 - Income_per_Family_Member: -0.8 đến -0.3
 - PC1_TotalPurchases_Total: -1.0 đến -0.5
 - PC1_AvgPerPurchase_Income: -0.9 đến -0.4
- Hành vi mua sắm
 - Hành vi: Đã lâu không mua (50+ ngày), lịch sử mua rất ít, giá trị thấp, thu nhập thấp.
 - Tâm lý: Khách hàng “ngủ quên”, không còn quan tâm, có thể đã chuyển sang thương hiệu khác.
- Ý nghĩa kinh doanh: Nguy cơ mất vĩnh viễn, chỉ nên đầu tư win-back có chọn lọc.

– Tổng kết

Khi áp dụng mô hình K-Means với $K = 2$, dữ liệu khách hàng được chia thành hai nhóm rõ rệt:

- Cụm 0 – At-Risk High-Value Customers: nhóm khách hàng có thu nhập cao, từng mua nhiều và giá trị mỗi lần mua lớn, nhưng hiện đang giảm hoạt động (Recency ~49 ngày). Đây là nhóm VIP có nguy cơ rời bỏ, cần chiến lược tái kích hoạt để giữ chân.
- Cụm 1 – Emerging Potential Customers: nhóm khách hàng thu nhập thấp, lịch sử mua ít và giá trị mỗi lần mua nhỏ, song vẫn còn hoạt động gần đây. Đây là nhóm tiềm năng, cần nuôi dưỡng để phát triển thành khách hàng trung thành. → Phân cụm $K = 2$ mang lại sự đơn giản, dễ quản lý, và làm nổi bật sự khác biệt giữa rủi ro mất khách VIP và cơ hội phát triển khách mới.

Với $K = 5$, mô hình cho kết quả chi tiết hơn, phân tách thành năm nhóm hành vi:

- Cúm 0 – VIPs (Recent & High-Value): khách hàng trung thành, chi tiêu cao, cần giữ chân và upsell.
 - Cúm 1 – Plateauing Customers: khách hàng tốt nhưng có dấu hiệu giảm nhiệt, cần kích thích tăng tần suất mua.
 - Cúm 2 – Mainstream Customers: khách hàng phổ thông, mua ở mức trung bình, dễ bị lôi kéo bởi giá cả, cần tăng engagement.
 - Cúm 3 – New or Occasional Buyers: khách mới hoặc mua ít, nhạy cảm với giá, cần nuôi dưỡng để phát triển.
 - Cúm 4 – At-Risk Dormant Customers: khách hàng đã lâu không mua, nguy cơ mất vĩnh viễn, chỉ nên đầu tư win-back có chọn lọc. →
- Phân cụm $K = 5$ giúp nhận diện chi tiết hơn các hành vi và tâm lý, hỗ trợ xây dựng chiến lược marketing chuyên biệt cho từng nhóm, nhưng cũng làm tăng độ phức tạp trong quản lý.


– Kết luận

- $K = 2$: phù hợp cho phân tích tổng quan, dễ triển khai chiến lược giữ chân và phát triển khách hàng.
- $K = 5$: cung cấp cái nhìn sâu hơn, giúp tối ưu hóa chiến dịch marketing theo từng phân khúc cụ thể, nhưng cần nguồn lực quản lý nhiều hơn.

4.2. Sử dụng thư viện

Kết quả thực nghiệm khi áp dụng mô hình có sẵn trong thư viện Sklearn cho ra các cụm phân tích tương tự với mô hình tự xây dựng. Điều này khẳng định rằng mô hình tự cài đặt đã hoạt động chính xác và có độ tin cậy cao.

4.2.1. Demographic



CHƯƠNG 4. KẾT QUẢ THỰC NGHIỆM

Tiêu chí	Mô hình tự cài đặt	Mô hình sử dụng thư viện	Đánh giá
1. Inertia (WCSS)	973.95	973.95	Giống nhau
2. Silhouette Score	0.3505	0.3506	Sai khác: $0.0001 \approx 0.03\%$ – Không đáng kể
3. Cluster Distribution	C0: 517 (25.7%) C1: 670 (33.3%) C2: 823 (40.9%)	C0: 512 (25.5%) C1: 822 (40.9%) C2: 676 (33.6%)	Khác về phân bố & chỉ số cụm
4. Centroid Locations	Giá trị rất gần nhau, sai khác < 0.02	Giá trị rất gần nhau, sai khác < 0.02	
5. Iterations	23	9	WL nhanh hơn $\sim 2.56x$ – do tối ưu hóa sklearn


Kết luận:

CHƯƠNG 4. KẾT QUẢ THỰC NGHIỆM

- **Độ chính xác:** Inertia và Silhouette gần như giống nhau → Mã tự cài đặt chính xác và đáng tin cậy.
- **Phân bổ cụm:** Khác về thứ tự và số lượng phần tử do hoán vị nhãn cụm - là điều bình thường trong K-Means. Chất lượng phân cụm tương đương nhau.
- **Vị trí Centroid:** Sai khác rất nhỏ (< 0.03), chấp nhận được.
- **Hiệu năng:** Sklearn nhanh hơn ~ 2.5 lần (do tối ưu hóa C), Mã tự cài đặt tuy chậm hơn nhưng dễ hiểu.

Kết luận cuối: Mô hình tự cài đặt hoạt động chính xác, khác biệt chỉ ở sai số nhỏ, hoán vị nhãn cụm và tốc độ chậm hơn. Vì vậy ta có thể sử dụng mô hình tự cài đặt với độ tin cậy cao.

4.2.2. Product Channel



CHƯƠNG 4. KẾT QUẢ THỰC NGHIỆM

Tiêu chí	Mô hình tự cài đặt	Mô hình sử dụng thư viện	Đánh giá
Inertia (WCSS)	1654.91	1654.90	Sai khác: 0.01
Silhouette Score	0.2849	0.2850	Sai khác: 0.0001
Cluster Distribution	C0: 479 (23.8%) C1: 604 (30.0%) C2: 518 (25.8%) C3: 409 (20.3%)	C0: 415 (20.6%) C1: 608 (30.2%) C2: 506 (25.2%) C3: 481 (23.9%)	Khác nhãn cụm, chất lượng tương đương
Centroid Locations	Sai khác < 0.02, giá trị rất gần nhau	Sai khác < 0.02, giá trị rất gần nhau	Tương đương
Iterations	20	12	Mô hình sử dụng thư viện nhanh hơn ~1.67x

Kết luận


- Độ chính xác:** Inertia (1654.91 vs 1654.90) và Silhouette (0.2849 vs 0.2850) gần như giống hệt nhau (sai khác < 0.01%) → Mã tự cài đặt hoạt động chính xác và đáng tin cậy.

CHƯƠNG 4. KẾT QUẢ THỰC NGHIỆM

- **Phân bổ cụm:** Khác về thứ tự nhãn do hoán vị (bình thường trong K-Means). Chất lượng phân cụm tương đương.
- **Centroid:** Sai khác rất nhỏ (< 0.02), chấp nhận được.
- **Hiệu năng:** Sklearn nhanh hơn ~ 1.67 lần (12 vs 20 iterations) nhờ tối ưu hóa C. Custom chậm hơn nhưng dễ hiểu cho học tập.

Kết luận cuối: Mô hình tự cài đặt chính xác và đáng tin cậy. Khác biệt chỉ ở sai số nhỏ, hoán vị nhãn và tốc độ chậm hơn. Vì thế mô hình tự cài đặt là lý tưởng cho công việc học tập/tự nghiên cứu, còn mô hình sử dụng thư viện có thể áp dụng để tạo ra sản phẩm.

4.2.3. RFM



CHƯƠNG 4. KẾT QUẢ THỰC NGHIỆM

Tiêu chí	NL (Custom)	WL (Sklearn)	Đánh giá
Inertia (WCSS)	1413.58	1413.58	0% sai khác
Silhouette Score	0.4393	0.4394	Sai khác: 0.0001
Cluster Distribution	C0: 949 (47.2%) C1: 1,061 (52.8%)	C0: 946 (47.1%) C1: 1,064 (52.9%)	Sai khác: ± 3 phần tử $\approx 0.15\%$
Centroid Locations	Sai khác rất nhỏ (< 0.003), giá trị gần như giống nhau	Sai khác rất nhỏ (< 0.003)	Floating-point precision
Iterations	14	7	Mô hình sử dụng thư viện nhanh hơn $\sim 2.0x$

– Kết luận:

- **Độ chính xác:** Inertia (1413.58 vs 1413.58) và Silhouette Score (0.4393 vs 0.4394) gần như giống hệt nhau (sai khác $< 0.01\%$) → Mã tự cài đặt hoạt động chính xác và đáng tin cậy.
- **Phân bổ cụm:** Gần như giống nhau, sai khác chỉ 3 khách hàng trên tổng 2.010 ($\approx 0.15\%$) → hoàn toàn bình thường.
- **Vị trí Centroid:** Sai khác rất nhỏ (< 0.003), không ảnh hưởng đến chất lượng phân cụm.
- **Hiệu năng:** Sklearn nhanh hơn ~2 lần (7 vs 14 iterations) nhờ tối ưu hóa C; mã tự cài đặt chậm hơn nhưng dễ hiểu cho học tập.
- **Chất lượng phân cụm:** RFM có Silhouette Score cao nhất (0.4393) so với các bộ dữ liệu khác → phân nhóm khách hàng rõ ràng hơn.

– Kết luận cuối

Mô hình tự cài đặt chính xác và đáng tin cậy. Khác biệt chỉ ở sai số nhỏ, phân bổ cụm gần như giống nhau và tốc độ chậm hơn → Dùng mô hình tự cài đặt cho phân tích/học tập, Sklearn cho sản phẩm.

CHƯƠNG 5. KẾT LUẬN

5.1. Kết quả đạt được

Quá trình phân cụm bằng K-Means đã được triển khai thành công trên ba lĩnh vực dữ liệu khách hàng:

- Demographic Segmentation: Xác định 3 cụm dựa trên tuổi, thu nhập và tỉ lệ phụ thuộc. Các cụm phản ánh rõ sự khác biệt về cấu trúc gia đình và giai đoạn cuộc sống (gia đình trẻ, độc thân thu nhập cao, và nhóm trưởng thành).

- RFM Segmentation: Xác định 2 cụm rõ rệt phân biệt khách hàng giá trị cao và thấp. Đây là kết quả có chất lượng tốt nhất với Silhouette Score cao (0.4394), cho phép đưa ra chiến lược chăm sóc và tái kích hoạt khách hàng hiệu quả.

- Product+Channel Segmentation: Xác định 4 cụm dựa trên hành vi mua hàng và kênh mua sắm. Các cụm thể hiện các nhóm hành vi khác nhau như “Wine Enthusiasts”, “Balanced Buyers”, “Premium Product Seekers” và “Online Engagers”, hỗ trợ tối ưu hóa chiến lược sản phẩm và kênh bán hàng.

⇒ Nhìn chung, các cụm được tạo ra đều mang ý nghĩa kinh doanh thực tế, giúp doanh nghiệp định hình chiến lược marketing và chăm sóc khách hàng theo từng phân khúc.

5.2. Những khó khăn, hạn chế

- Chất lượng phân cụm trung bình: Silhouette Score dao động từ 0.28 đến 0.44, phản ánh ranh giới cụm chưa thật sự rõ ràng, đặc biệt trong dữ liệu Product+Channel.

- Khách hàng nằm ở ranh giới cụm: Một số điểm dữ liệu có Silhouette Score âm, cho thấy sự chồng lấp tự nhiên trong hành vi và đặc điểm khách hàng.

- Phương pháp chọn số cụm (K): Elbow và Silhouette đôi khi đưa ra gợi ý khác nhau, cần kết hợp cả hai và cân nhắc yếu tố kinh doanh để quyết định K tối ưu.

- Đặc thù dữ liệu khách hàng: Dữ liệu phức tạp, đa chiều, chứa ngoại lệ tự nhiên khiến việc phân cụm khó đạt được sự tách biệt hoàn hảo.

TÀI LIỆU THAM KHẢO

- [1] C. P. Analysis, “Kaggle,” [Trực tuyến]. Available: <https://www.kaggle.com/datasets/imakash3011/customer-personality-analysis..>
- [2] C. S. P. KMeans, “Kaggle,” [Trực tuyến]. Available: <https://www.kaggle.com/code/manarsaber/customer-segmentation-pca-kmeans..>

PHỤ LỤC

Bảng phân công công việc của các thành viên trong nhóm

STT	Nội dung công việc	23DH114778 Trương Gia Nghị	23DH111855 Đoàn Thanh Sang	23DH113038 Trần Lâm Hồng Liên
1	Tiền xử lý dữ liệu	20%	60%	20%
2	Xây dựng đặc trưng	20%	20%	60%
3	Xây dựng mô hình	60%	20%	20%